

浙江大学

运筹学大作业报告



攻击视觉大模型！

Attacking Vision-Language Models!

学 生 姓 名： 张天羽 江征远 金震庭 田 阔

专 业 名 称： 自动化（控制）

所 在 学 院： 控制科学与工程学院

二〇二六年六月十一日

目 录

目 录.....	II
1 绪论.....	1
1.1 选题意义	1
1.2 问题叙述	1
2 带二范数约束的非线性规划模型（解析法）	4
2.1 建立模型	4
2.2 Lagrange 函数法	5
2.3 Fritz John 条件.....	6
2.4 Kuhn-Tucker 条件	7
2.5 实验结果	9
2.5.1 一阶 Lagrange 满意解	10
2.5.2 二阶 KKT 近似解.....	11
3 带二范数约束的非线性规划模型（数值法）	13
3.1 建立模型	13
3.1.1 加权和无约束模型.....	13
3.1.2 攻击阈值约束模型与外点罚函数.....	13
3.1.3 二范数约束模型.....	14
3.2 迭代法	14
3.2.1 最速下降法.....	15
3.2.2 牛顿法与 Levenberg-Marquardt 修正	15
3.2.3 DFP 拟牛顿法	15
3.2.4 非线性共轭梯度法.....	16
3.2.5 二范数约束下的投影梯度法.....	16
3.3 实验结果	17
3.3.1 加权和模型：最速下降法.....	17
3.3.2 加权和模型：牛顿法.....	18
3.3.3 加权和模型：Levenberg-Marquardt 修正	19
3.3.4 加权和模型：DFP 变尺度法.....	20
3.3.5 加权和模型：Fletcher-Reeves 共轭梯度法.....	21
3.3.6 加权和模型：Polak-Ribiere+共轭梯度法	22
3.3.7 Courant 外点罚函数法	23
3.3.8 Softplus 光滑外点罚函数法.....	24
3.3.9 二范数球投影梯度法.....	25

4 化为对偶问题并求解.....	28
4.1 化为对偶问题	28
4.2 弱对偶、强对偶与对偶间隙.....	29
4.3 KKT 条件	29
4.4 数值求解	30
4.5 实验结果	31
5 让模型将任何东西识别为厕纸.....	33
5.1 建立模型	33
5.2 数值求解	33
5.3 实验结果	34
6 面积最小的“张天羽”.....	36
6.1 建立模型	36
6.1.1 图像网格图.....	36
6.1.2 字形模板.....	36
6.1.3 0-1 非线性规划模型.....	37
6.1.4 基于网络流的连通性模型.....	38
6.1.5 基于一阶近似的混合整数线性规划模型.....	38
6.2 反向贪心剪枝	39
6.3 实验结果	40
6.3.1 逆向贪心剪枝.....	40
6.3.2 一阶线性化 MILP	41
7 小组分工.....	43
参考文献.....	44
附 录.....	46

1 绪论

1.1 选题意义

随着人工智能技术的发展，视觉分类模型已经广泛应用于自动驾驶、无人机侦察、军事目标识别、智能安防、工业检测、人脸识别、遥感图像分析等场景。对于一个视觉分类系统而言，其基本任务是：给定一幅输入图像，模型自动判断图像所属类别。例如，在交通场景中，模型需要识别交通标志、行人、车辆和障碍物；在军事场景中，模型可能需要识别飞机、舰船、导弹发射装置或地面目标；在公共安全领域，模型可能需要识别危险物品、异常行为或敏感目标。

然而，现代视觉模型虽然在标准测试集上具有较高准确率，但其决策过程通常是由大量非线性运算组合而成，外部观察者难以直接解释其内部判别机制。因此，在实际应用中，视觉模型可能面临有意设计的输入干扰。**所谓攻击视觉模型，并不是指破坏模型参数，而是指给输入图像增加某种肉眼难以察觉的扰动，使模型决策发生错误，以达到破坏性的目的。**

这种问题具有重要现实意义。

第一，从信息安全角度看，视觉模型已经成为许多智能系统的入口。如果输入图像经微小扰动后即可导致系统误判，则说明系统存在潜在安全风险。例如，智能门禁、安防监控、自动审核系统和身份识别系统都可能受到输入层面的干扰。

第二，从国家安全角度看，视觉识别系统被广泛应用于军事侦察、无人系统导航、战场态势感知和目标检测。如果敌方能够通过物理图案、伪装涂装或局部遮挡干扰识别系统，则可能影响军事装备的识别、跟踪和决策。

第三，从运筹学角度看，该问题本质上可以被抽象为一个带约束的非线性优化问题。其决策变量是图像像素扰动，目标函数是分类器的损失函数或分类置信度函数，约束条件是扰动幅度、图像取值范围、扰动面积或扰动形状。因此，攻击视觉模型不仅是人工智能安全问题，也可以作为传统运筹学中非线性规划、目标规划、罚函数法、对偶理论、数值优化和图论方法的综合应用案例。

本文选择 MobileNetV2 分类模型作为被攻击模型，尝试建立攻击的 MobileNetV2 数学模型，并分别使用传统解析法、传统数值法、对偶思想以及图论方法进行建模与算法设计。

1.2 问题叙述

MobileNetV2 是一种轻量级卷积神经网络，主要用于图像分类任务。它的设计目标是在保持较好分类精度的同时降低计算量和参数量，因此常被用于移动端、嵌入式设备和资源受限场景。TorchVision 官方文档说明，MobileNetV2 的模型构建器可以使用不同的预训练权重，其中包括 ImageNet-1K 权重；PyTorchHub 也说明，预训练视觉模型通常期望输入为三通道 RGB 图像，并进行标准归一化处理。

设输入图像为 $x \in \mathbb{R}^{H \times W \times C}$ ，对于实验中的 ImageNet-1K 输入尺寸，取 $H = 224, W = 224, C = 3$ ，因此输入可展开为一个向量：

$$x = (x_1, x_2, \dots, x_n)^\top \in \mathbb{R}^n, \quad (1-1)$$

其中 $n = 224 \times 224 \times 3 = 150528$ ，而每个 x_i 表示图像中的一个颜色通道像素值。例如，左上角像素的红色通道、绿色通道、蓝色通道分别可以对应三个不同的决策变量。

MobileNetV2 是一个多类别分类函数，可表示为

$$F: \mathbb{R}^{150528} \rightarrow \mathbb{R}^K. \quad (1-2)$$

在 ImageNet-1K 分类任务中, $K = 1000$, 因此, 模型输出为

$$F(x) = (z_1(x), z_2(x), z_{1000}(x))^T. \quad (1-3)$$

其中 $z_i(x)$ 称为第 i 类的 **logit**, 也可理解为第 i 类的未归一化得分函数。MobileNetV2 的 TorchVision 源码实现中, 分类器部分包含线性层, 输出类别数由 `num_classes` 控制; 使用 ImageNet 权重时对应 ImageNet-1K 分类任务。

对于输入图像 x , 分类器首先计算所有类别的得分:

$$z_1(x), z_2(x), \dots, z_K(x). \quad (1-4)$$

然后通过最大得分规则得到预测类别:

$$\hat{y}(x) = \arg \max_{1 \leq j \leq K} z_j(x). \quad (1-5)$$

若真实类别为 y , 则分类正确的条件为

$$\hat{y}(x) = y. \quad (1-6)$$

若经过扰动后的图像为

$$x' = x + \delta, \quad (1-7)$$

则攻击成功的条件为

$$\hat{y}(x + \delta) \neq y. \quad (1-8)$$

MobileNetV2 对输入图像的处理过程可以抽象为一系列函数复合。设模型共有 L 层, 则可以写为

$$F(x) = F_L \circ F_{L-1} \circ \dots \circ F_2 \circ F_1(x). \quad (1-9)$$

其中, 各层可能包括卷积、批归一化、ReLU6 激活、深度可分离卷积、倒残差结构、全局平均池化和线性分类层, 如图 1-1 所示:




图 1-1 MobileNetV2 各层示意图

因此, 每一个 **logit** 都可以看成输入图像像素的非线性函数:

$$z_j(x) = z_j(x_1, x_2, \dots, x_{150528}), j = 1, 2, \dots, 1000. \quad (1-10)$$

为了将分类问题转化为可微优化问题, 通常引入 **softmax** 概率:

$$p_j(x) = \frac{e^{z_j(x)}}{\sum_{k=1}^K e^{z_k(x)}}. \quad (1-11)$$

其中 $p_j(x)$ 可理解为模型将输入图像 x 判断为第 j 类的归一化概率。

对于真实类别 y ，定义交叉熵损失函数：

$$J(x, y) = -\log p_y(x). \quad (1-12)$$

将 softmax 展开，可得

$$J(x, y) = -\log \frac{e^{z_y(x)}}{\sum_{j=1}^K e^{z_j(x)}}. \quad (1-13)$$

进一步化简：

$$J(x, y) = -\left[z_y(x) - \log \left(\sum_{j=1}^K e^{z_j(x)} \right) \right], \quad (1-14)$$

即

$$J(x, y) = \log \left(\sum_{j=1}^K e^{z_j(x)} \right) - z_y(x). \quad (1-15)$$

当模型对真实类别 y 越自信时， $p_y(x)$ 越大， $J(x, y)$ 越小；当模型对真实类别 y 越不自信时， $p_y(x)$ 越小， $J(x, y)$ 越大。

因此，从攻击角度来看，目标并不是减小 $J(x, y)$ ，而是希望增大 $J(x, y)$ 。为了化为标准型，我们定义攻击目标函数

$$\Phi(x, y) = -J(x, y). \quad (1-16)$$

于是，攻击问题可以写成非线性规划问题

$$\boxed{\min \Phi(x + \delta, y) = -J(x + \delta, y)}. \quad (1-17)$$

当 Φ 越小，等价于 J 越大，模型对真实类别的决策越不稳定，容易产生决策错误，达到攻击目的。

2 带二范数约束的非线性规划模型（解析法）

式(1-21)建立的模型是一个无约束的非线性规划模型。为了使图像扰动无法被敌人肉眼察觉，我们对图像扰动施加二范数约束，建立带二范数约束的非线性规划模型。在本章中，我们首先采用解析法求解，依次尝试了 Lagrange 函数法、Fritz John 条件和 Kuhn-Tucker 条件。

2.1 建立模型

设原始图像为

$$x \in \mathbb{R}^n, n = 150528. \quad (2-1)$$

设扰动向量为

$$\delta \in \mathbb{R}^n. \quad (2-2)$$

扰动后图像为

$$x' = x + \delta. \quad (2-3)$$

为了使图像扰动无法被敌人肉眼察觉，引入二范数平方约束：

$$\|\delta\|_2^2 \leq \varepsilon^2. \quad (2-4)$$

其中

$$\|\delta\|_2^2 = \sum_{i=1}^n \delta_i^2. \quad (2-5)$$

此外，由于图像像素通常需要限制在合法范围内，若像素归一化到[0, 1]，则还应满足盒约束：

$$0 \leq x_i + \delta_i \leq 1, i = 1, 2, \dots, n. \quad (2-6)$$

为了突出主模型，本节首先研究二范数平方约束，盒约束可在后续数值实现中通过投影或附加不等式处理。

攻击模型可写为：

$$\begin{aligned} \min_{\delta \in \mathbb{R}^n} \quad & \Phi(\delta) = z_y(x + \delta) - \log \left(\sum_{j=1}^K e^{z_j(x + \delta)} \right) \\ \text{s.t.} \quad & \|\delta\|_2^2 \leq \varepsilon^2. \end{aligned} \quad (2-7)$$

记约束函数为

$$g(\delta) = \varepsilon^2 - \|\delta\|_2^2. \quad (2-8)$$

则约束为

$$g(\delta) \geq 0. \quad (2-9)$$

因此模型为标准不等式约束非线性规划：

$$\begin{aligned} \min_{\delta} \quad & \Phi(\delta) \\ \text{s.t.} \quad & g(\delta) \geq 0. \end{aligned} \quad (2-10)$$

二范数平方为

$$\|\delta\|_2^2 = \delta^\top \delta. \quad (2-11)$$

其梯度为

$$\nabla_{\delta} \|\delta\|_2^2 = 2\delta. \quad (2-12)$$

其 Hessian 矩阵为

$$\nabla_{\delta}^2 \|\delta\|_2^2 = 2I. \quad (2-13)$$

因此，二范数平方是处处可导、处处二阶可导的光滑凸函数。

约束函数 $g(\delta) = \varepsilon^2 - \delta^\top \delta$ 的梯度为

$$\nabla g(\delta) = -2\delta. \quad (2-14)$$

Hessian 为

$$\nabla^2 g(\delta) = -2I. \quad (2-15)$$

因此约束集合 $\{\delta: \|\delta\|_2^2 \leq \varepsilon^2\}$ 是一个闭球，是凸集。

然而，目标函数 $\Phi(\delta)$ 是由 MobileNetV2 的 logit 函数复合而成。由于 $\Phi(\delta)$ 一般是非凸函数，所以该问题不是凸规划，而是具有凸可行域的非凸非线性规划问题。

2.2 Lagrange 函数法

对于问题

$$\begin{aligned} \min_{\delta} \quad & \Phi(\delta) \\ \text{s.t.} \quad & g(\delta) \geq 0, \end{aligned} \quad (2-10)$$

构造 Lagrange 函数：

$$L(\delta, \lambda) = \Phi(\delta) - \lambda g(\delta). \quad (2-16)$$

即

$$L(\delta, \lambda) = \Phi(\delta) - \lambda(\varepsilon^2 - \delta^\top \delta). \quad (2-17)$$

其中 λ 为 Lagrange 乘子。

如果最优解位于约束边界上，即

$$\|\delta\|_2^2 = \varepsilon^2, \quad (2-18)$$

则可按等式约束处理，令

$$h(\delta) = \varepsilon^2 - \delta^\top \delta = 0. \quad (2-19)$$

此时 Lagrange 必要条件为：

$$\nabla_{\delta} L(\delta, \lambda) = 0, \quad (2-20)$$

即

$$\nabla \Phi(\delta) - \lambda \nabla h(\delta) = 0. \quad (2-21)$$

由于

$$\nabla h(\delta) = -2\delta, \quad (2-22)$$

可得

$$\nabla \Phi(\delta) + 2\lambda \delta = 0. \quad (2-23)$$

于是

$$\nabla \Phi(\delta) = -2\lambda \delta. \quad (2-24)$$

若 $\lambda \neq 0$ ，则

$$\delta = -\frac{1}{2\lambda} \nabla \Phi(\delta). \quad (2-25)$$

这说明，在边界最优点处，扰动方向与目标函数梯度方向共线。

由于

$$\Phi(\delta) = -J(x + \delta, y), \quad (2-26)$$

所以

$$\nabla \Phi(\delta) = -\nabla_{\delta} J(x + \delta, y). \quad (2-27)$$

于是

$$-\nabla_{\delta} J(x + \delta, y) + 2\lambda \delta = 0. \quad (2-28)$$

即

$$2\lambda \delta = \nabla_{\delta} J(x + \delta, y). \quad (2-29)$$

因此

$$\delta = \frac{1}{2\lambda} \nabla_{\delta} J(x + \delta, y). \quad (2-30)$$

这个式子说明：为了增大损失函数 J ，扰动方向应当与损失函数关于输入的梯度方向相关。但由于 $\nabla_{\delta} J(x + \delta, y)$ 本身依赖于 δ ，这是一个隐式方程。一般不能直接解析求出全局最优解。因此，进一步采用一阶泰勒近似。

在 $\delta = 0$ 附近展开：

$$J(x + \delta, y) \approx J(x, y) + \nabla_x J(x, y)^{\top} \delta. \quad (2-31)$$

于是

$$\Phi(\delta) = -J(x + \delta, y) \approx -J(x, y) - \nabla_x J(x, y)^{\top} \delta. \quad (2-32)$$

由于 $-J(x, y)$ 与 δ 无关，可忽略常数项，近似问题为：

$$\begin{aligned} \min_{\delta} \quad & -\nabla_x J(x, y)^{\top} \delta \\ \text{s.t.} \quad & \|\delta\|_2^2 \leq \varepsilon^2. \end{aligned} \quad (2-33)$$

等价于：

$$\begin{aligned} \max_{\delta} \quad & \nabla_x J(x, y)^{\top} \delta \\ \text{s.t.} \quad & \|\delta\|_2 \leq \varepsilon. \end{aligned} \quad (2-34)$$

根据 Cauchy-Schwarz 不等式：

$$\nabla_x J(x, y)^{\top} \delta \leq \|\nabla_x J(x, y)\|_2 \|\delta\|_2. \quad (2-35)$$

又因为 $\|\delta\|_2 \leq \varepsilon$ ，所以

$$\nabla_x J(x, y)^{\top} \delta \leq \varepsilon \|\nabla_x J(x, y)\|_2. \quad (2-36)$$

当 $\delta = \varepsilon \frac{\nabla_x J(x, y)}{\|\nabla_x J(x, y)\|_2}$ 时等号成立。

因此，基于一阶泰勒近似和 Lagrange 思想，可得到解析扰动方向：

$$\delta^{(1)} = \varepsilon \frac{\nabla_x J(x, y)}{\|\nabla_x J(x, y)\|_2}. \quad (2-37)$$

该解是一阶泰勒近似模型下的全局最优解。对于原始非凸问题，它只是一个基于局部梯度信息构造的可行近似扰动，不能保证是原问题的局部最优解或全局最优解。

2.3 Fritz John 条件

Fritz John 条件适用于更一般的约束优化问题。对于问题

$$\begin{aligned} \min_{\delta} \quad & \Phi(\delta) \\ \text{s.t.} \quad & g(\delta) \geq 0, \end{aligned} \quad (2-10)$$

Fritz John 条件指出：若 δ^* 是局部最优解，则存在不全为零的乘子 $\lambda_0 \geq 0, \lambda_1 \geq 0$ ，使得

$$\lambda_0 \nabla \Phi(\delta^*) - \lambda_1 \nabla g(\delta^*) = 0, \quad (2-38)$$

同时满足

$$\begin{aligned} \lambda_1 g(\delta^*) &= 0, \\ g(\delta^*) &\geq 0, \\ \lambda_0, \lambda_1 &\geq 0. \end{aligned} \quad (2-39)$$

代入

$$g(\delta) = \varepsilon^2 - \delta^\top \delta, \quad (2-8)$$

可得

$$\lambda_0 \nabla \Phi(\delta^*) + 2\lambda_1 \delta^* = 0. \quad (2-40)$$

如果 $\lambda_0 > 0$ ，则两边除以 λ_0 ，令 $\lambda = \frac{\lambda_1}{\lambda_0}$ ，得到

$$\nabla \Phi(\delta^*) + 2\lambda \delta^* = 0.$$

这就退化为 KKT 条件中的驻点方程。

对于本问题，假设 $\varepsilon > 0$ 。若最优点位于球内部，则 $g(\delta^*) > 0$ ，由互补松弛条件可得 $\lambda_1 = 0$ 。由于 Fritz John 乘子不全为零，必有 $\lambda_0 > 0$ 。若最优点位于球面上，则 $\|\delta^*\|_2 = \varepsilon > 0$ ，从而 $\nabla g(\delta^*) = -2\delta^* \neq 0$ 。若令 $\lambda_0 = 0$ ，Fritz John 驻点条件将推出 $\lambda_1 = 0$ ，与乘子不全为零矛盾。因此仍有 $\lambda_0 > 0$ 。所以，本问题的任意局部最优解均满足 $\lambda_0 > 0$ 。将 Fritz John 条件除以 λ_0 ，即可得 KKT 条件。

因此，Fritz John 条件可用于说明局部最优解必须满足的广义必要条件，但不能直接给出解析最优扰动，也不能保证全局最优。

2.4 Kuhn-Tucker 条件

对于问题

$$\begin{aligned} \min_{\delta} \quad & \Phi(\delta) \\ \text{s.t.} \quad & g(\delta) \geq 0, \end{aligned} \quad (2-10)$$

Kuhn-Tucker 条件为：

第一，原始可行性：

$$g(\delta^*) \geq 0. \quad (2-41)$$

第二，对偶可行性：

$$\lambda^* \geq 0. \quad (2-42)$$

第三，互补松弛条件：

$$\lambda^* g(\delta^*) = 0. \quad (2-43)$$

第四，驻点条件：

$$\nabla \Phi(\delta^*) - \lambda^* \nabla g(\delta^*) = 0. \quad (2-44)$$

由于

$$\nabla g(\delta^*) = -2\delta^*, \quad (2-45)$$

所以

$$\nabla \Phi(\delta^*) + 2\lambda^* \delta^* = 0. \quad (2-46)$$

又因为

$$\Phi(\delta) = -J(x + \delta, y), \quad (2-47)$$

所以

$$-\nabla_{\delta} J(x + \delta^*, y) + 2\lambda^* \delta^* = 0. \quad (2-48)$$

因此

$$2\lambda^* \delta^* = \nabla_{\delta} J(x + \delta^*, y). \quad (2-49)$$

若约束不起作用，则 $g(\delta^*) > 0$ 。由互补松弛条件可得 $\lambda^* = 0$ ，此时驻点条件变为 $\nabla \Phi(\delta^*) = 0$ ，这表示最优解是目标函数在球内部的驻点。但对于攻击问题，一般希望在给定扰动预算内尽量增大损失，因此最优解经常位于球面上，即 $g(\delta^*) = 0$ 。但约束起作用并不一定意味着 $\lambda^* > 0$ 。仅当确认 $\lambda^* > 0$ 时，才能由驻点条件写出：

$$\delta^* = \frac{1}{2\lambda^*} \nabla_{\delta} J(x + \delta^*, y). \quad (2-50)$$

同样，这是一个隐式方程。由于目标函数非凸，KKT 条件一般只是局部最优的必要条件，不保证全局最优。

如果对目标函数进行一阶泰勒展开，则可以得到上一节中的闭式满意解：

$$\delta^{(1)} = \varepsilon \frac{\nabla_x J(x, y)}{\|\nabla_x J(x, y)\|_2}. \quad (2-51)$$

若进行二阶泰勒展开，则有：

$$J(x + \delta, y) \approx J(x, y) + g^{\top} \delta + \frac{1}{2} \delta^{\top} H \delta, \quad (2-52)$$

其中

$$\begin{aligned} g &= \nabla_x J(x, y), \\ H &= \nabla_x^2 J(x, y). \end{aligned} \quad (2-53)$$

于是近似攻击问题变为：

$$\begin{aligned} \max_{\delta} \quad & g^{\top} \delta + \frac{1}{2} \delta^{\top} H \delta \\ \text{s.t.} \quad & \delta^{\top} \delta \leq \varepsilon^2. \end{aligned} \quad (2-54)$$

等价地，写成最小化形式：

$$\begin{aligned} \min_{\delta} \quad & -g^{\top} \delta - \frac{1}{2} \delta^{\top} H \delta \\ \text{s.t.} \quad & \varepsilon^2 - \delta^{\top} \delta \geq 0. \end{aligned} \quad (2-55)$$

构造 Lagrange 函数：

$$L(\delta, \lambda) = -g^{\top} \delta - \frac{1}{2} \delta^{\top} H \delta - \lambda(\varepsilon^2 - \delta^{\top} \delta). \quad (2-56)$$

驻点条件为：

$$-g - H\delta + 2\lambda\delta = 0. \quad (2-57)$$

即

$$(2\lambda I - H)\delta = g. \quad (2-58)$$

当 $\lambda > 0$ 且 $2\lambda I - H$ 可逆时，约束必起作用，可以结合 $\delta(\lambda) = (2\lambda I - H)^{-1}g$ 与 $\delta(\lambda)^{\top} \delta(\lambda) = \varepsilon^2$ 求解乘子。同时还需检验 $2\lambda I - H \geq 0$ 。若 $\lambda = 0$ ，则应检查是否存在球内部最优解。此外，仅当 $H \leq 0$ 时，该最小化形式的目标函数才是凸函数；一般情况下它是非凸 QCQP。

该二阶近似模型比一阶模型更精细，但需要 Hessian 矩阵，计算代价极高。因此它更适合作为理论推导，而不一定适合作为大规模实际求解方法。二阶近似模型的解是局部二次模型下的最优解，

对于原始神经网络非凸问题，一般只能视作局部解或满意解。

2.5 实验结果

本文统一选取 4 张原图生成攻击图，四张原图如图 2-1 所示。跑车与波斯猫这两张图片的共同特征是主体明显、单一，适合检验二范数约束扰动在清晰单目标图像上的攻击效果；雏菊图片的主体同样明显，但花朵数量较多，图像内部存在多个重复显著区域，适合观察扰动在多主体场景中的稳定性。温莎结领带图片是一张人类难以达成分类共识的图片：它既可能被理解为原始人、西装客、梗图，也可能被模型归入其他视觉模式，因此其分类结果更依赖模型自身的决策边界。



图 2-1 本文统一选取 4 张原图

在代码实现方面，本文所有实验都有 2 套版本：在 **manual** 版本中，我们尝试了手搓求解器；在 **efficient** 版本中，我们调用现有的求解器，以对比手搓求解器与开源求解器的效果与效率。实验结果如下：


2.5.1 一阶 Lagrange 满意解



(a) 原图: sports car
14.517%

(a1) 攻击图: convertible
7.4182%

(a2) 扰动图
 $L_2 = 3.8236$



(b) 原图: Persian cat
9.729%

(b1) 攻击图: paper towel
4.8748%


(b2) 扰动图
 $L_2 = 4.0000$



(c) 原图: Windsor tie
12.536%

(c1) 攻击图: groom
7.9366%

(c2) 扰动图
 $L_2 = 3.9995$



(d) 原图: daisy
13.113%

(d1) 攻击图: handkerchief
12.6193%

(d2) 扰动图
 $L_2 = 4.0000$

图 2-2 一阶 Lagrange 满意解

2.5.2 二阶 KKT 近似解




图 2-3 二阶 KKT 近似解

表 2-1 带二范数约束的非线性规划模型（解析法）实验结果

方法	求解器	成功率	平均耗时/s	最大耗时/s	平均决策函数值/%	平均 L_2
一阶 Lagrange 满意解	manual	4/4	0.079	0.201	8.212	3.956
一阶 Lagrange 满意解	efficient	4/4	0.070	0.164	8.212	3.956
二阶 KKT 近似解	manual	4/4	56.442	69.630	8.269	3.923
二阶 KKT 近似解	efficient	4/4	55.922	66.698	8.269	3.923

两类解析近似方法均达到 100%成功率，说明在二范数半径为 4 的可行域内，四张图像的原始决策点均离模型分类边界较近。该问题具有凸的二范数球可行域，但目标函数来自神经网络复合映射，整体并非凸规划，因此实验结果更应理解为局部近似模型给出的满意解，而不是原非凸问题的全局最优证明。

一阶 Lagrange 满意解几乎把波斯猫、温莎结和雏菊三张图的扰动推到半径边界，体现出二范数约束在 KKT 语言中的起作用约束特征：当内部驻点不足以改变分类时，最有效的可行方向往往位于球面边界。二阶 KKT 近似在前三张图上平均 L_2 略小，说明 Hessian 信息能够修正纯梯度方向，使候选点更贴近局部曲率下的边界；但其耗时约为一阶方法的 700 倍，计算代价主要来自二阶近似和线性方程求解。二阶方法更接近局部最优性检验；对实际实验而言，一阶方法已经以极低的成本给出稳定可行解。

3 带二范数约束的非线性规划模型（数值法）

上一章采用解析法研究了带二范数约束的攻击模型，并说明原问题的目标函数通常非凸，KKT 条件一般只能给出局部最优解的必要条件，难以直接得到全局解析解。因此，本章采用数值迭代方法求取局部驻点或满意解。

我们首先区分了三类彼此相关但含义不同的模型：加权和无约束模型、攻击阈值约束模型和二范数约束模型；随后按照下降迭代法的统一框架，分别讨论最速下降法、牛顿法、DFP 拟牛顿法、非线性共轭梯度法、外点罚函数法和投影梯度法。

3.1 建立模型

3.1.1 加权和无约束模型

设原始图像为 $x \in \mathbb{R}^n$ ，扰动为 $\delta \in \mathbb{R}^n$ ，损失函数为 $J(x + \delta, y)$ 。为了同时控制扰动规模并增大攻击损失，可采用加权和标量化方法，建立无约束模型

$$\min_{\delta \in \mathbb{R}^n} Q(\delta) = \|\delta\|_2^2 - PJ(x + \delta, y), P > 0. \quad (3-1)$$

其中， P 为权重系数。 P 较大时，模型更重视增大攻击损失； P 较小时，模型更重视减小扰动规模。该模型是后文最速下降法、牛顿法、DFP 拟牛顿法和非线性共轭梯度法的主要研究对象。

在 J 可微处，目标函数的梯度为

$$\nabla Q(\delta) = 2\delta - P\nabla_{\delta} J(x + \delta, y). \quad (3-2)$$

在 J 二阶可微处，目标函数的 Hessian 矩阵为

$$\nabla^2 Q(\delta) = 2I - P\nabla_{\delta}^2 J(x + \delta, y). \quad (3-3)$$

由于神经网络目标函数通常非凸， $\nabla^2 Q(\delta)$ 不一定正定。此外，MobileNetV2 中含有 ReLU6 等分段线性激活函数，目标函数在少数分界点可能不可微或不可二阶微。以下推导均在目标函数局部可微或采用光滑近似的条件下进行。

3.1.2 攻击阈值约束模型与外点罚函数

若希望在攻击损失达到给定阈值的前提下使扰动尽可能小，可建立约束模型

$$\begin{aligned} & \min_{\delta \in \mathbb{R}^n} \|\delta\|_2^2 \\ & \text{s.t. } g_{\eta}(\delta) = J(x + \delta, y) - \eta \geq 0, \end{aligned} \quad (3-4)$$

其中， η 为期望达到的攻击损失水平。

按照 Courant 外点罚函数法，对约束违反量进行平方惩罚，构造

$$F(\delta, M_k) = \|\delta\|_2^2 + M_k [\min\{0, g_{\eta}(\delta)\}]^2, M_k > 0. \quad (3-5)$$

等价地，

$$F(\delta, M_k) = \|\delta\|_2^2 + M_k [\max\{\eta - J(x + \delta, y), 0\}]^2. \quad (3-6)$$

当 $J(x + \delta, y) \geq \eta$ 时，罚项为零；当约束受到违反时，罚项为正。外点罚函数法需要逐步增大罚因子，而不是仅固定一个罚因子。取 $M_1 > 0$ 、放大系数 $c > 1$ ，可采用如下外层迭代：

$$\delta^{(k)} \approx \arg \min_{\delta} F(\delta, M_k), M_{k+1} = cM_k. \quad (3-7)$$

当约束违反量

$$\max\{\eta - J(x + \delta^{(k)}, y), 0\} \leq \varepsilon_c \quad (3-8)$$

时停止外层迭代。由于原问题非凸，实际计算通常只能近似求得每个罚函数子问题的局部极小点，因此最终结果一般是原约束问题的局部解或满意解。

若数值算法要求目标函数更加光滑，可用 **Softplus** 函数

$$\psi_\alpha(u) = \frac{1}{\alpha} \log(1 + e^{\alpha u}), \alpha > 0, \quad (3-9)$$

近似 $\max\{u, 0\}$ ，从而构造光滑近似罚函数

$$\tilde{F}(\delta, M_k) = \|\delta\|_2^2 + M_k[\psi_\alpha(\eta - J(x + \delta, y))]^2. \quad (3-10)$$

需要注意，**Softplus** 在约束满足时仍严格大于零，因此式(3-10)是对原罚函数的光滑近似，而不是与式(3-5)完全等价的罚函数。

3.1.3 二范数约束模型

若直接保留上一章的扰动预算约束，则研究

$$\begin{aligned} \min_{\delta \in \mathbb{R}^n} \Phi(\delta) &= -J(x + \delta, y) \\ \text{s.t.} \quad g(\delta) &= \varepsilon^2 - \|\delta\|_2^2 \geq 0. \end{aligned} \quad (3-11)$$

其可行域为二范数闭球

$$B_2(\varepsilon) = \{\delta \in \mathbb{R}^n: \|\delta\|_2 \leq \varepsilon\}. \quad (3-12)$$

本章使用投影梯度法求解式(3-11)。加权和模型、外点罚函数模型与二范数约束模型是三种不同的建模和求解路径，后文分别讨论，不在同一迭代公式中混用。

3.2 迭代法

对于无约束问题

$$\min_{\delta \in \mathbb{R}^n} f(\delta), \quad (3-13)$$

下降迭代法的一般格式为

$$\delta^{(k+1)} = \delta^{(k)} + \alpha_k d_k, \alpha_k > 0, \quad (3-14)$$

其中， d_k 为搜索方向， α_k 为迭代步长。若 $\nabla f(\delta^{(k)})^\top d_k < 0$ ，则 d_k 为当前点的下降方向。对于充分小的正步长，有

$$f(\delta^{(k+1)}) < f(\delta^{(k)}). \quad (3-15)$$

步长可通过一维搜索确定。精确一维搜索定义为

$$\alpha_k^* = \arg \min_{\alpha \geq 0} f(\delta^{(k)} + \alpha d_k). \quad (3-16)$$

当精确一维搜索计算代价过高时，也可使用近似一维搜索选择能够使目标函数充分下降的步长。

数值迭代不能无限进行，需要设置终止准则。对于无约束问题，可采用以下一种或多种准则：

$$\begin{aligned} \|\nabla f(\delta^{(k)})\|_2 &\leq \varepsilon_g, \\ \|\delta^{(k+1)} - \delta^{(k)}\|_2 &\leq \varepsilon_x, \\ |f(\delta^{(k+1)}) - f(\delta^{(k)})| &\leq \varepsilon_f. \end{aligned} \quad (3-17)$$

此外，还应设置最大迭代次数，以避免算法在数值误差或非光滑点附近长期停滞。

3.2.1 最速下降法

对于加权和无约束模型(3-1)，记 $g_k = \nabla Q(\delta^{(k)})$ 。最速下降方向为负梯度方向 $d_k = -g_k$ 。当 $g_k \neq 0$ 时， $g_k^\top d_k = -\|g_k\|_2^2 < 0$ ，因此 d_k 是下降方向。结合式(3-2)，最速下降法的迭代公式为

$$\delta^{(k+1)} = \delta^{(k)} - \alpha_k \nabla Q(\delta^{(k)}) = \delta^{(k)} - \alpha_k [2\delta^{(k)} - P\nabla_\delta J(x + \delta^{(k)}, y)]. \quad (3-18)$$

整理可得

$$\delta^{(k+1)} = (1 - 2\alpha_k)\delta^{(k)} + \alpha_k P\nabla_\delta J(x + \delta^{(k)}, y). \quad (3-19)$$

式(3-20)表明，迭代同时受到扰动收缩项和损失梯度上升项的影响。步长 α_k 应通过一维搜索或其他合理规则确定；仅有 $\alpha_k > 0$ 并不能保证目标函数下降。

采用精确一维搜索时，新点处梯度与上一搜索方向正交：

$$\nabla Q(\delta^{(k+1)})^\top d_k = 0. \quad (3-20)$$

最速下降法计算量小，适合高维问题，但在狭长等高线区域可能出现之字形迭代，接近极值点时收敛速度通常较慢。由于 Q 一般非凸，该方法不能保证得到全局最优解。

3.2.2 牛顿法与 Levenberg-Marquardt 修正

在当前点 $\delta^{(k)}$ 附近，对 Q 作二阶泰勒展开：

$$Q(\delta^{(k)} + s) \approx Q(\delta^{(k)}) + g_k^\top s + \frac{1}{2} s^\top B_k s, \quad (3-21)$$

其中

$$g_k = \nabla Q(\delta^{(k)}), B_k = \nabla^2 Q(\delta^{(k)}). \quad (3-22)$$

牛顿方向 s_k 由牛顿方程确定：

$$B_k s_k = -g_k. \quad (3-23)$$

对于本文的加权和模型，牛顿方程为

$$[2I - P\nabla_\delta^2 J(x + \delta^{(k)}, y)]s_k = P\nabla_\delta J(x + \delta^{(k)}, y) - 2\delta^{(k)}. \quad (3-24)$$

随后进行迭代

$$\delta^{(k+1)} = \delta^{(k)} + \alpha_k s_k. \quad (3-25)$$

实际计算时应求解线性方程(3-23)，而不应显式计算 B_k^{-1} 。当 $B_k > 0$ 时，

$$g_k^\top s_k = -g_k^\top B_k^{-1} g_k < 0, \quad (3-26)$$

因此牛顿方向是下降方向。若 B_k 非正定，牛顿方向可能不是下降方向。按照 Levenberg-Marquardt 的修正思想，可改为求解

$$(B_k + \mu_k I)s_k = -g_k, \mu_k > 0, \quad (3-27)$$

并选择 μ_k 使

$$B_k + \mu_k I > 0. \quad (3-28)$$

此时 s_k 为下降方向。当 μ_k 较小时，修正方向接近牛顿方向；当 μ_k 较大时，修正方向接近负梯度方向。

本问题的输入维数为 $n = 150528$ ，完整 Hessian 矩阵规模为 150528×150528 ，存储和求解牛顿方程的代价极高。因此，牛顿法和 LM 修正更适合作为理论分析或低维近似模型的求解方法。

3.2.3 DFP 拟牛顿法

拟牛顿法不直接计算 Hessian 矩阵，而是利用迭代信息构造 Hessian 逆的近似。设 H_k 为 $[\nabla^2 Q(\delta^{(k)})]^{-1}$ 的近似矩阵，取初始矩阵 $H_0 = I$ ，DFP 方法的搜索方向为

$$d_k = -H_k g_k, g_k = \nabla Q(\delta^{(k)}). \quad (3-29)$$

若 $H_k > 0$ 且 $g_k \neq 0$, 则

$$g_k^\top d_k = -g_k^\top H_k g_k < 0, \quad (3-30)$$

因此 d_k 为下降方向。迭代点由

$$\delta^{(k+1)} = \delta^{(k)} + \alpha_k d_k \quad (3-31)$$

确定。记 $s_k = \delta^{(k+1)} - \delta^{(k)}, y_k = g_{k+1} - g_k$, DFP 更新公式为

$$H_{k+1} = H_k + \frac{s_k s_k^\top}{s_k^\top y_k} - \frac{H_k y_k y_k^\top H_k}{y_k^\top H_k y_k}. \quad (3-32)$$

这一更新满足拟牛顿条件 $H_{k+1} y_k = s_k$ 。当曲率条件 $s_k^\top y_k > 0$ 成立时, DFP 更新可以保持近似矩阵的正定性。对于严格凸二次函数, 配合精确一维搜索, DFP 法具有二次终止性; 但本文目标函数一般非凸, 因此该性质通常不再成立。

完整存储 H_k 仍需 $O(n^2)$ 空间, 不适合直接处理超高维图像变量。实际计算可采用有限记忆拟牛顿思想, 仅保存最近若干组 (s_k, y_k) 。需要说明的是, 有限记忆实现通常采用 L-BFGS, 其更新形式与本节的 DFP 教材推导不同, 但二者均属于拟牛顿方法。

3.2.4 非线性共轭梯度法

标准共轭梯度法适用于正定二次优化问题

$$\min_{\delta \in \mathbb{R}^n} \frac{1}{2} \delta^\top A \delta - b^\top \delta, A = A^\top > 0. \quad (3-33)$$

其搜索方向满足关于 A 的共轭关系

$$d_i^\top A d_j = 0, i \neq j. \quad (3-34)$$

对于一般非线性目标函数 Q , 可采用非线性共轭梯度法。令 $g_k = \nabla Q(\delta^{(k)})$, 初始方向为 $d_0 = -g_0$ 。当 $k \geq 1$ 时, 搜索方向为 $d_k = -g_k + \beta_k d_{k-1}$ 。

Fletcher-Reeves 参数为

$$\beta_k^{\text{FR}} = \frac{g_k^\top g_k}{g_{k-1}^\top g_{k-1}}, \quad (3-35)$$

Polak-Ribiere 参数为

$$\beta_k^{\text{PR}} = \frac{g_k^\top (g_k - g_{k-1})}{g_{k-1}^\top g_{k-1}}. \quad (3-36)$$

为了提高一般非线性问题中的稳定性, 可采用自动重置形式

$$\beta_k^{\text{PR}+} = \max\{\beta_k^{\text{PR}}, 0\}. \quad (3-37)$$

若计算得到的方向不满足下降条件, 即 $g_k^\top d_k \geq 0$, 则令 $d_k = -g_k$ 进行重启。迭代公式为

$$\delta^{(k+1)} = \delta^{(k)} + \alpha_k d_k, \quad (3-38)$$

其中步长应通过适当的一维搜索确定。

对于正定二次函数, 在精确一维搜索下, 共轭梯度法最多经过 n 步即可到达极小点。对于本文非凸非线性目标, 该二次终止性不再成立, 但非线性共轭梯度法仍具有无需存储 Hessian、存储量较小和适合大规模问题等优点。

3.2.5 二范数约束下的投影梯度法

对于二范数约束模型(3-11), 普通无约束下降迭代可能产生不可行点。投影梯度法首先沿负梯

度方向迭代，再将结果投影回可行域：

$$\delta^{(k+1)} = \Pi_{B_2(\varepsilon)}[\delta^{(k)} - \alpha_k \nabla \Phi(\delta^{(k)})]. \quad (3-39)$$

由于

$$\Phi(\delta) = -J(x + \delta, y), \nabla \Phi(\delta) = -\nabla_{\delta} J(x + \delta, y), \quad (3-40)$$

式(3-39)可写为

$$\delta^{(k+1)} = \Pi_{B_2(\varepsilon)}[\delta^{(k)} + \alpha_k \nabla_{\delta} J(x + \delta^{(k)}, y)]. \quad (3-41)$$

对于任意 $v \in \mathbb{R}^n$ ，其在二范数闭球上的欧氏投影为

$$\Pi_{B_2(\varepsilon)}(v) = \begin{cases} v, & \|v\|_2 \leq \varepsilon, \\ \varepsilon \frac{v}{\|v\|_2}, & \|v\|_2 > \varepsilon. \end{cases} \quad (3-42)$$

投影后的迭代点始终满足 $\|\delta^{(k)}\|_2 \leq \varepsilon$ 。然而，投影梯度法的终止条件不能简单使用 $\nabla \Phi(\delta^{(k)}) = 0$ ，因为约束最优点处的普通梯度通常不为零。定义投影梯度映射

$$G_{\alpha_k}(\delta^{(k)}) = \frac{1}{\alpha_k} [\delta^{(k)} - \Pi_{B_2(\varepsilon)}(\delta^{(k)} - \alpha_k \nabla \Phi(\delta^{(k)}))], \quad (3-43)$$

可采用 $\|G_{\alpha_k}(\delta^{(k)})\|_2 \leq \varepsilon_p$ 作为一阶终止准则。

若进一步考虑像素盒约束 $0 \leq x + \delta \leq 1$ ，完整可行域为二范数球与盒约束的交集。此时不能直接使用式(3-57)代替交集上的投影，而应求解相应的欧氏投影子问题。

3.3 实验结果

3.3.1 加权和模型：最速下降法



(a) 原图：sports car


14.517%

(a1) 攻击图：pickup

26.3531%

(a2) 扰动图

$L_2 = 7.1967$



(b) 原图：Persian cat

9.729%

(b1) 攻击图：paper towel

44.0947%

(b2) 扰动图

$L_2 = 11.8668$





图 3-1 加权和模型：最速下降法

3.3.2 加权和模型：牛顿法






(c) 原图: Windsor tie
12.536%

(c1) 攻击图: hog
48.5944%

(c2) 扰动图
 $L_2 = 9.5552$



(d) 原图: daisy
13.113%

(d1) 攻击图: handkerchief
37.3499%

(d2) 扰动图
 $L_2 = 9.4913$

图 3-2 加权和模型: 牛顿法

3.3.3 加权和模型: Levenberg-Marquardt 修正



(a) 原图: sports car
14.517%

(a1) 攻击图: pickup
26.3531%

(a2) 扰动图
 $L_2 = 7.1967$



(b) 原图: Persian cat
9.729%

(b1) 攻击图: paper towel
47.7373%

(b2) 扰动图
 $L_2 = 11.6113$





图 3-3 加权模型: Levenberg-Marquardt 修正

3.3.4 加权模型: DFP 变尺度法





(c) 原图: Windsor tie
12.536%

(c1) 攻击图: hog
27.3859%

(c2) 扰动图
 $L_2 = 7.8149$



(d) 原图: daisy
13.113%

(d1) 攻击图: handkerchief
41.1281%

(d2) 扰动图
 $L_2 = 13.4634$

图 3-4 加权和模型: DFP 变尺度法


3.3.5 加权和模型: Fletcher-Reeves 共轭梯度法



(a) 原图: sports car
14.517%

(a1) 攻击图: grille
28.5023%

(a2) 扰动图
 $L_2 = 11.6288$



(b) 原图: Persian cat
9.729%

(b1) 攻击图: paper towel
51.9728%

(b2) 扰动图
 $L_2 = 16.4981$



(c) 原图: Windsor tie
12.536%

(c1) 攻击图: hog
27.6661%

(c2) 扰动图
 $L_2 = 11.1521$



(d) 原图: daisy
13.113%

(d1) 攻击图: handkerchief
41.1274%

(d2) 扰动图
 $L_2 = 12.6655$

图 3-5 加权和模型: Fletcher-Reeves 共轭梯度法


3.3.6 加权和模型: Polak-Ribiere+共轭梯度法



(a) 原图: sports car
14.517%

(a1) 攻击图: grille
28.3311%

(a2) 扰动图
 $L_2 = 10.1449$



(b) 原图: Persian cat
9.729%

(b1) 攻击图: paper towel
53.9945%

(b2) 扰动图
 $L_2 = 16.4456$



(c) 原图: Windsor tie
12.536%

(c1) 攻击图: hog
35.4590%

(c2) 扰动图
 $L_2 = 14.1171$



(d) 原图: daisy
13.113%

(d1) 攻击图: handkerchief
41.0890%

(d2) 扰动图
 $L_2 = 13.7842$

图 3-6 加权模型: Polak-Ribiere+共轭梯度法


3.3.7 Courant 外点罚函数法



(a) 原图: sports car
14.517%

(a1) 攻击图: convertible
7.2773%

(a2) 扰动图
 $L_2 = 7.0175$



(b) 原图: Persian cat
9.729%

(b1) 攻击图: paper towel
13.7810%

(b2) 扰动图
 $L_2 = 6.8265$





图 3-7 Courant 外点罚函数法

3.3.8 Softplus 光滑外点罚函数法






图 3-8 Softplus 光滑外点罚函数法

3.3.9 二范数球投影梯度法






图 3-9 二范数球投影梯度法

表 3-1 带二范数约束的非线性规划模型（数值法）实验结果

方法	求解器	成功率	平均耗时/s	最大耗时/s	平均决策函数数值/%	平均 L_2
加权和-最速下降	manual	4/4	0.238	0.244	39.138	9.728
加权和-最速下降	efficient	4/4	0.499	0.511	82.402	5.843
加权和-牛顿法	manual	4/4	6.901	10.782	37.421	9.732
加权和-牛顿法	efficient	4/4	0.491	0.508	82.402	5.843
加权和-LM修正	manual	4/4	6.906	10.502	40.670	9.379
加权和-LM修正	efficient	4/4	0.502	0.515	82.402	5.843
加权和-DFP变尺度	manual	4/4	0.232	0.244	36.367	11.891

加权和- DFP 变尺度	efficient	4/4	0.500	0.517	82.402	5.843
加权和-FR 共轭梯度	manual	4/4	0.271	0.301	37.317	12.986
加权和-FR 共轭梯度	efficient	4/4	0.494	0.510	82.402	5.843
加权和- PR+ 共轭 梯度	manual	4/4	0.280	0.326	39.718	13.623
加权和- PR+ 共轭 梯度	efficient	4/4	0.497	0.512	82.402	5.843
Courant 外 点罚函数	manual	4/4	0.234	0.250	9.681	6.655
Courant 外 点罚函数	efficient	4/4	0.831	1.362	5.004	0.255
Softplus 光 滑外点罚函 数	manual	4/4	0.247	0.271	9.681	6.655
Softplus 光 滑外点罚函 数	efficient	4/4	1.344	1.428	5.492	0.201
二范数球投 影梯度	manual	4/4	0.229	0.234	31.465	2.629
二范数球投 影梯度	efficient	4/4	0.218	0.222	31.465	2.629

数值法都取得 100%成功率，但不同模型对应的运筹学含义并不相同。**加权和模型把攻击成功**和扰动较小写成同一个无约束目标，它更接近目标规划中的加权偏差处理：权重给定后，求解器追求的是综合指标的下降，而不是严格把扰动压在某个硬边界上。因此该类方法的决策函数值普遍较大，说明攻击约束存在较大余量。

从下降迭代法角度看，manual 后端的最速下降、DFP 和共轭梯度均在 0.3 秒内完成，可见梯度型方法计算量小、适合大规模问题。牛顿法和 LM 修正平均耗时约 6.9 秒，因为它们利用二阶信息或二阶近似，单步方向质量更高，但需要额外计算曲率信息。LM 修正的平均 L_2 为 9.379，略低于普通牛顿法的 9.732，说明把非正定或病态 Hessian 修正为更稳定的下降方向后，局部求解更平稳。

外点罚函数和投影梯度体现了两类不同的约束处理。外点法通过罚因子把约束违反量并入目标函数，manual 后端给出的平均 L_2 为 6.655，攻击余量较充足；efficient 后端则把平均 L_2 压到 0.201 到 0.255，说明其更接近边界解。投影梯度法每步都把扰动映射回二范数球可行域，平均 L_2 为 2.629，兼顾了较强攻击效果和明确的原始可行性。若从可行方向法看，投影梯度的优势在于每一步都保持可行候选，而外点法的优势在于可以先在可行域外搜索，再通过罚函数逐步逼近约束边界。

4 化为对偶问题并求解

第2章和第3章主要采用形式：

$$\begin{aligned} \min_{\delta} \quad & -J(x + \delta, y) \\ \text{s.t.} \quad & \|\delta\|_2^2 \leq \varepsilon^2. \end{aligned} \quad (4-1)$$

该模型表示：限制最大的扰动，追求最大的破坏。

接下来，我们将其化为对偶问题：限制最小的破坏，追求最小的扰动。

给定扰动预算 ε 时，可研究预算约束模型

$$\begin{aligned} \max_{\delta \in \mathbb{R}^n} \quad & J(x + \delta, y) \\ \text{s.t.} \quad & \|\delta\|_2 \leq \varepsilon. \end{aligned} \quad (4-2)$$

给定攻击损失阈值 η 时，可研究阈值约束模型

$$\begin{aligned} \min_{\delta \in \mathbb{R}^n} \quad & \|\delta\|_2^2 \\ \text{s.t.} \quad & J(x + \delta, y) \geq \eta. \end{aligned} \quad (4-3)$$

前者限制最大扰动并追求尽可能强的攻击效果，后者限制最低攻击效果并追求尽可能小的扰动。二者反映了扰动规模与攻击效果之间的 Pareto 权衡，但一般不能简单地互称为原问题和对偶问题。

当 $\eta \leq J(x, y)$ 时，原始图像已经达到给定阈值， $\delta = 0$ 即为阈值约束模型的全局最优解。当 η 超过模型在允许输入范围内能够达到的最大损失时，阈值约束模型无可行解。因此，阈值 η 的选取应兼顾攻击要求与可行性。

在 J 连续、 $\eta > J(x, y)$ 且阈值约束模型可行时，其全局最优解通常满足 $J(x + \delta^*, y) = \eta$ 。这是因为，若某个最优解满足严格不等式 $J(x + \delta^*, y) > \eta$ ，则沿从0到 δ^* 的线段移动，根据连续性，可以在更小扰动范数处首次达到阈值 η ，从而与 δ^* 的最优性矛盾。

本章选择攻击阈值约束模型作为原问题。定义扰动目标函数 $D(\delta) = \|\delta\|_2^2$ 和约束函数 $c(\delta) = J(x + \delta, y) - \eta$ 。原问题写为

$$\begin{aligned} \text{原问题}(P_\eta): \quad & \min_{\delta \in \mathbb{R}^n} D(\delta) = \|\delta\|_2^2 \\ \text{s.t.} \quad & c(\delta) = J(x + \delta, y) - \eta \geq 0. \end{aligned} \quad (4-4)$$

与约束 $c(\delta) \geq 0$ 对应的 Lagrange 乘子应满足非负条件，并在 Lagrange 函数中以减号出现。

本文首先研究仅包含攻击阈值约束的简化模型。若同时考虑图像像素范围，还应增加 $x + \delta \in [0, 1]^n$ 等约束。增加这些约束后，应为每个不等式约束分别引入非负 Lagrange 乘子。

4.1 化为对偶问题

对原问题 (P_η) ，引入非负乘子 $\lambda \geq 0$ ，构造 Lagrange 函数

$$\begin{aligned} L(\delta, \lambda) &= D(\delta) - \lambda c(\delta) = \|\delta\|_2^2 - \lambda [J(x + \delta, y) - \eta] \\ &= \|\delta\|_2^2 - \lambda J(x + \delta, y) + \lambda \eta. \end{aligned} \quad (4-5)$$

对于固定的 $\lambda \geq 0$ ，对原变量 δ 取全局下确界，定义对偶函数

$$q(\lambda) = \inf_{\delta \in \mathbb{R}^n} L(\delta, \lambda) = \lambda \eta + \inf_{\delta \in \mathbb{R}^n} [\|\delta\|_2^2 - \lambda J(x + \delta, y)]. \quad (4-6)$$

由此得到对偶问题

$$\text{对偶问题}(D_\eta): \max_{\lambda \geq 0} q(\lambda). \quad (4-7)$$

对于每一个给定的乘子 λ ，计算对偶函数都要求求解 Lagrange 松弛子问题

$$\inf_{\delta \in \mathbb{R}^n} [\|\delta\|_2^2 - \lambda J(x + \delta, y)]. \quad (4-8)$$

对偶函数 $q(\lambda)$ 是一族关于 λ 的仿射函数的逐点下确界，因此无论原问题是否为凸规划， $q(\lambda)$ 都是凹函数。若某些 λ 使内层目标函数无下界，则对应 $q(\lambda) = -\infty$ 。实际求解前应确认所研究范围内的 Lagrange 松弛子问题具有有限下确界。

4.2 弱对偶、强对偶与对偶间隙

设原问题最优值为

$$p^* = \inf_{\delta: c(\delta) \geq 0} D(\delta), \quad (4-9)$$

对偶问题最优值为

$$d^* = \sup_{\lambda \geq 0} q(\lambda). \quad (4-10)$$

对于任意原问题可行解 δ 和任意对偶可行解 $\lambda \geq 0$ ，由于 $c(\delta) \geq 0$ ，有

$$L(\delta, \lambda) = D(\delta) - \lambda c(\delta) \leq D(\delta). \quad (4-11)$$

又因为 $q(\lambda)$ 是 $L(\delta, \lambda)$ 关于 δ 的下确界，所以

$$q(\lambda) \leq L(\delta, \lambda) \leq D(\delta). \quad (4-12)$$

因此总有弱对偶关系 $d^* \leq p^*$ 。这说明，对偶问题给出的目标函数值是原问题最小扰动值的下界。弱对偶性不要求原问题为凸规划。

定义对偶间隙为 $p^* - d^* \geq 0$ ，若 $p^* = d^*$ ，则称强对偶成立。如果目标函数 $D(\delta)$ 为凸函数，约束函数 $c(\delta)$ 为凹函数，并满足适当的约束资格条件，例如存在严格可行点使 $c(\delta) > 0$ ，则原问题属于凸规划，通常可以建立强对偶关系。

在本文问题中， $D(\delta) = \|\delta\|_2^2$ 是凸函数，但 $c(\delta) = J(x + \delta, y) - \eta$ 一般不是凹函数，因为神经网络损失关于输入通常是非凸函数。因此，原问题一般不是凸规划，强对偶和零对偶间隙均不能保证。即使对偶问题被精确求解，也只能保证得到原问题最优值的下界，不能仅凭对偶最优解恢复原问题的全局最优解。

4.3 KKT 条件

假设 J 在候选点附近可微，且局部最优点满足适当的约束资格条件，则原问题的局部最优解 δ^* 必须满足 KKT 条件。

原始可行性为 $J(x + \delta^*, y) - \eta \geq 0$ ，对偶可行性为 $\lambda^* \geq 0$ ，互补松弛条件为

$$\lambda^* [J(x + \delta^*, y) - \eta] = 0. \quad (4-13)$$

驻点条件为

$$\nabla_{\delta} L(\delta^*, \lambda^*) = 0, \quad (4-14)$$

即

$$2\delta^* - \lambda^* \nabla_{\delta} J(x + \delta^*, y) = 0. \quad (4-15)$$

因此，在 $\lambda^* > 0$ 时，

$$\delta^* = \frac{\lambda^*}{2} \nabla_{\delta} J(x + \delta^*, y). \quad (4-16)$$

这说明，在满足 KKT 条件的候选解处，最优扰动与损失函数关于输入的梯度方向相关。

互补松弛条件只说明 $\lambda^* > 0 \Rightarrow J(x + \delta^*, y) = \eta$ ，一般不能仅由约束起作用反推出 $\lambda^* > 0$ 。但是，对于本文的简化模型，若 $\eta > J(x, y)$ 、问题可行且 KKT 条件成立，则 $\delta^* \neq 0$ 。结合驻点条件可知此时 $\lambda^* \neq 0$ ，从而有 $\lambda^* > 0, J(x + \delta^*, y) = \eta$ 。若 $\eta < J(x, y)$ ，则 $\delta^* = 0$ 已经严格满足攻击阈值，最优乘子可取 $\lambda^* = 0$ 。

在强对偶成立的凸规划情形下，KKT 条件通常既是最优性的必要条件，也是充分条件。对于本文非凸问题，KKT 条件一般只是正则局部最优解的必要条件；满足 KKT 条件的点也可能不是局部最优解。

乘子 λ^* 还可以解释为攻击阈值的影子价格。在适当的正则条件下，若原问题最优值记为 $p^*(\eta)$ ，则 λ^* 反映了提高攻击阈值 η 对最小扰动代价的边际影响。通常，阈值要求越高，达到该阈值所需的最小扰动也越大。

4.4 数值求解

对偶函数为

$$q(\lambda) = \lambda\eta + \inf_{\delta} (\|\delta\|_2^2 - \lambda J(x + \delta, y)). \quad (4-17)$$

若对固定的 $\lambda^{(t)}$ 能够求得内层问题的全局最优解

$$\delta(\lambda^{(t)}) \in \arg \min_{\delta} (\|\delta\|_2^2 - \lambda^{(t)} J(x + \delta, y)), \quad (4-18)$$

则根据对偶函数的定义，

$$s_t = \eta - J(x + \delta(\lambda^{(t)}), y) \quad (4-19)$$

是对偶凹函数 q 在 $\lambda^{(t)}$ 处的一个超梯度。于是可使用投影超梯度上升法更新乘子：

$$\lambda^{(t+1)} = \max \{0, \lambda^{(t)} + \rho_t [\eta - J(x + \delta(\lambda^{(t)}), y)]\}, \quad (4-20)$$

其中 $\rho_t > 0$ 为外层步长。

该更新具有清晰的经济含义：若当前内层解尚未达到攻击阈值，即 $J(x + \delta(\lambda^{(t)}), y) < \eta$ ，则提高乘子 λ ，使下一次内层求解更加重视增大攻击损失；若当前内层解显著超过阈值，则更新可能降低乘子，从而更加重视减小扰动规模。

对于固定的 λ ，内层目标函数为

$$Q_{\lambda}(\delta) = \|\delta\|_2^2 - \lambda J(x + \delta, y), \quad (4-21)$$

其梯度为

$$\nabla Q_{\lambda}(\delta) = 2\delta - \lambda \nabla_{\delta} J(x + \delta, y). \quad (4-22)$$

内层可以使用第 3 章讨论的最速下降法、拟牛顿法或非线性共轭梯度法。例如，最速下降迭代为

$$\delta^{(k+1)} = \delta^{(k)} - \alpha_k (2\delta^{(k)} - \lambda \nabla_{\delta} J(x + \delta^{(k)}, y)). \quad (4-23)$$

步长 α_k 应通过合理的一维搜索或其他下降规则确定。

需要强调的是，对偶函数中的内层运算是全局下确界。由于 $Q_{\lambda}(\delta)$ 一般非凸，使用下降法通常只能得到局部极小点。若以内层局部极小值代替全局下确界，则计算结果不一定是真实的 $q(\lambda)$ ，也不一定仍是原问题最优值的有效下界。此时，双层迭代只能称为近似原-对偶算法或启发式乘子调整方法。

为降低非凸性带来的影响，数值计算中可采用多个初始点求解内层问题，并保留目标函数值最小的结果。同时应持续记录满足原始约束的候选扰动，并在所有可行候选中选择扰动范数最小者作为最终输出。

4.5 实验结果



图 4-1 化为对偶问题并求解

表 4-1 化为对偶问题并求解实验结果						
方法	求解器	成功率	平均耗时/s	最大耗时/s	平均决策函数值/%	平均 L_2
对偶损失双层迭代	manual	4/4	0.990	1.017	23.607	1.416
对偶损失双层迭代	efficient	4/4	1.990	1.999	64.246	2.759

化为对偶问题并求解是我们实验中的最佳方法。不但决策函数能达到很高的阈值，而且所需的扰动 L_2 远小于第 2 章与第 3 章的方法，肉眼几乎无法分辨攻击图上的扰动噪声。

manual 平均 L_2 为 1.416，正是连续攻击实验中扰动最小的一组；efficient 平均决策函数值更高，说明其选择了攻击余量更大的可行点，但代价是平均 L_2 上升到 2.759。这个现象与对偶乘子的解释一致：乘子可以看作攻击阈值约束的边际权重，权重更新越强调满足攻击约束，越容易得到决策函数值更大的解。但仍需注意，本问题不是线性规划或凸规划，这里的对偶求解更适合作为一种原问题-对偶问题交替调整的数值策略：内层寻找当前乘子下的原始可行候选，外层依据约束余量修正乘子。

5 让模型将任何东西识别为厕纸

前文尝试的攻击方法仅追求被攻击模型决策错误。本章尝试让被攻击模型产生指定错误，即把任何东西都识别为某一特定物品。MobileNetV2 对应 ImageNet-1K 的 1000 类物品，其中第 1000 类 ($t = 999$) 物品即为厕纸 (toilet tissue)，因此，不妨选取厕纸作为指定目标。

与非定向攻击相比，本章不仅要降低原类别的竞争力，还必须使厕纸的得分超过其他所有类别。因此，直接以厕纸与最强竞争类别之间的得分差作为决策函数。

5.1 建立模型

设原始图像为 $x \in \mathbb{R}^n$ ，扰动为 $\delta \in \mathbb{R}^n$ ，扰动后图像为

$$x' = x + \delta. \quad (5-1)$$

定义厕纸类别的定向分类间隔函数

$$M_t(\delta) = z_t(x + \delta) - \max_{j \neq t} z_j(x + \delta), t = 999. \quad (5-2)$$

当 $M_t(\delta) > 0$ 时，厕纸类别得分严格大于其他所有类别得分，模型将扰动后图像识别为厕纸。为避免不同类别得分相等时分类规则的不确定性，并保持一定安全余量，给定正的攻击阈值 $\eta > 0$ ，要求

$$M_t(\delta) \geq \eta. \quad (5-3)$$

阈值 η 越大，要求厕纸类别领先其他类别的程度越高，通常也需要更大的扰动。以二范数平方衡量扰动规模，可建立如下阈值约束非线性规划模型：

$$\begin{aligned} & \min_{\delta \in \mathbb{R}^n} \|\delta\|_2^2 \\ \text{s.t. } & M_t(\delta) - \eta \geq 0. \end{aligned} \quad (5-4)$$

记约束函数为

$$c_t(\delta) = M_t(\delta) - \eta, \quad (5-5)$$

则模型可简写为

$$\begin{aligned} & \min_{\delta \in \mathbb{R}^n} \|\delta\|_2^2 \\ \text{s.t. } & c_t(\delta) \geq 0. \end{aligned} \quad (5-6)$$

若原始图像已满足 $M_t(0) \geq \eta$ ，则 $\delta = 0$ 为全局最优解。若阈值超过模型在合法输入范围内能达到的最大定向分类间隔，则问题无可行解。因此，攻击阈值应兼顾攻击要求与问题可行性。

由于各 logit 是输入图像的非线性函数，且间隔函数中含有最大值运算，该模型一般为非凸非线性规划问题。即使求得满足一阶必要条件的点，也通常只能视为局部最优解或满意解。

为了与第 4 章保持一致，上述模型首先仅保留攻击阈值约束。数值实现时还应保证扰动后像素位于合法范围：

$$0 \leq x_i + \delta_i \leq 1, i = 1, 2, \dots, n. \quad (5-7)$$

该条件可通过增加约束处理，或在每次迭代后将扰动后图像投影回合法像素范围。

5.2 数值求解

本章模型与第 4 章攻击阈值约束模型结构相同，区别在于：第 4 章使用非定向攻击损失 $J(x + \delta, y)$ 衡量攻击效果，本章使用厕纸类别的定向分类间隔 $M_t(\delta)$ 衡量攻击效果。因此，可直接沿

用第 4 章的 Lagrange 松弛与双层迭代方法。

对约束 $c_t(\delta) \geq 0$ 引入非负 Lagrange 乘子 $\lambda \geq 0$ ，构造 Lagrange 函数

$$L_t(\delta, \lambda) = \|\delta\|_2^2 - \lambda[M_t(\delta) - \eta]. \quad (5-8)$$

对于固定乘子 λ ，求解内层无约束问题

$$\min_{\delta \in \mathbb{R}^n} Q_\lambda(\delta) = \|\delta\|_2^2 - \lambda M_t(\delta). \quad (5-9)$$

内层问题可采用最速下降法求局部极小点。记当前扰动下得分最高的非厕纸类别为

$$r(\delta) = \arg \max_{j \neq t} z_j(x + \delta). \quad (5-10)$$

当该类别唯一且 logit 可微时，有

$$\nabla M_t(\delta) = \nabla z_t(x + \delta) - \nabla z_{r(\delta)}(x + \delta), \quad (5-11)$$

从而

$$\nabla Q_\lambda(\delta) = 2\delta - \lambda \nabla M_t(\delta). \quad (5-12)$$

最速下降迭代公式为

$$\delta^{(k+1)} = \delta^{(k)} - \alpha_k [2\delta^{(k)} - \lambda \nabla M_t(\delta^{(k)})], \quad (5-13)$$

其中 $\alpha_k > 0$ 为迭代步长，可通过一维搜索或其他合理下降规则确定。当多个非厕纸类别并列取得最大得分时，间隔函数在该点可能不可微；实际计算中可从并列类别中选取一个类别计算方向，并继续迭代。

外层根据当前定向分类间隔与攻击阈值的差调整 λ ：

$$\lambda^{(s+1)} = \max\{0, \lambda^{(s)} + \rho_s [\eta - M_t(\delta(\lambda^{(s)}))]\}, \quad (5-14)$$

其中 $\rho_s > 0$ 为外层步长， $\delta(\lambda^{(s)})$ 为第 s 次外层迭代对应的内层近似解。若当前间隔不足，则提高乘子，使下一次内层求解更加重视提高厕纸类别得分；若间隔明显超过阈值，则允许降低乘子，使求解更注重减小扰动。

由于内层目标函数一般非凸，最速下降法通常只能求局部极小点。为减小初始点对结果影响，可采用多个初始扰动进行内层求解，并持续保留满足 $M_t(\delta) \geq \eta$ 的可行候选。在所有可行候选中，选择二范数最小者作为最终满意解。

5.3 实验结果






图 5-1 让模型将任何东西识别为厕纸

表 5-1 让模型将任何东西识别为厕纸实验结果

方法	求解器	成功率	平均耗时/s	最大耗时/s	平均决策函数数值/%	平均 L_2
定向 toilet tissue 攻击	manual	4/4	1.120	1.155	3.142	1.174
定向 toilet tissue 攻击	efficient	4/4	2.128	2.180	7.670	1.407

可见，模型将 4 张攻击图片全部识别为厕纸，攻击成功。因为本章同样利用了化为对偶问题的思想，所以攻击成功所需的扰动二范数较小。

6 面积最小的“张天羽”

前文尝试的攻击方法都追求使图像扰动无法被敌人肉眼察觉。本章考虑另一种情境：为了表达对敌人的嘲讽，在图片上增添纯黑色的文字或图案，例如“张天羽”三字，在攻击成功的前提下，使“张天羽”的面积尽量小。我们依次尝试建立了 0-1 非线性规划模型、基于网络流的连通性模型、基于一阶近似的混合整数线性规划模型，并采用反向剪枝等启发式方法求解。

该问题同时包含攻击约束、字形约束和连通约束三类条件。首先，置黑后的图像应当能够使被攻击模型产生错误输出；其次，被置黑像素应位于给定文字模板内，保留各笔画的基本结构；最后，同一笔画中被保留的像素应当在图像网格上相互连通。

因此，本章将该问题表述为一个带图结构约束的 0-1 非线性规划问题，并利用网络流模型刻画笔画连通性。在此基础上，进一步构造基于一阶近似的混合整数线性规划模型，并提出适用于大规模图像的启发式求解算法。

需要说明的是，本章研究的是字形模板约束下的稀疏置黑攻击。被置黑像素可以是完整文字模板的子集，但必须满足预先规定的笔画保留率和连通性要求。当所有笔画保留率均取 1 时，该模型退化为完整字形模板攻击。

6.1 建立模型

6.1.1 图像网格图

设输入图像的高度和宽度分别为 H 和 W ，像素位置总数为 $m = HW$ 。将每个像素位置视为一个顶点，记顶点集合为 $V = \{v_1, v_2, \dots, v_m\}$ 。若两个像素在空间上上下相邻或左右相邻，则在对应顶点之间连接一条无向边。由此得到图像四邻域网格图

$$G = (V, E), \quad (6-1)$$

其中

$$E = \left\{ \{v_i, v_j\} : v_i \text{ 与 } v_j \text{ 在图像中四邻接} \right\}. \quad (6-2)$$

在 $H \times W$ 的四邻域网格图中，无向边数为

$$|E| = H(W - 1) + W(H - 1). \quad (6-3)$$

当 $H = W = 224$ 时，顶点数和无向边数分别为

$$|V| = 50176, |E| = 99904. \quad (6-4)$$

为了使用网络流刻画连通性，将每条无向边替换为方向相反的两条弧，得到辅助有向弧集

$$A = \{(i, j), (j, i) : \{v_i, v_j\} \in E\}. \quad (6-5)$$

因此， 224×224 图像对应的有向弧数为

$$|A| = 2|E| = 199808. \quad (6-6)$$

上述定义严格区分了无向图中的“边”和网络流模型中的“弧”：字形连通性在无向图 G 上定义，而流量变量则在辅助有向网络 (V, A) 上定义。

6.1.2 字形模板

设 $T \subseteq V$ 为给定字号、位置和字体下“张天羽”三字所覆盖的候选像素集合。将文字模板分解为 L 个笔画或连通部件：

$$\mathcal{P} = \{P_1, P_2, \dots, P_L\}, P_l \subseteq T, \bigcup_{l=1}^L P_l = T. \quad (6-7)$$

对于每个笔画 P_l ，给定最小保留比例 $\gamma_l \in (0, 1]$ 。当 $\gamma_l = 1$ 时，该笔画必须完整保留；当 $0 < \gamma_l < 1$ 时，允许删除部分像素，但仍需保持笔画连通。

定义二元决策变量

$$s_i = \begin{cases} 1, & v_i \text{被置为黑色,} \\ 0, & v_i \text{保持原值.} \end{cases} \quad (6-8)$$

所有被置黑的像素构成顶点集合

$$S = \{v_i \in V: s_i = 1\}, \quad (6-9)$$

其面积以被置黑像素数衡量：

$$|S| = \sum_{i=1}^m s_i. \quad (6-10)$$

由于置黑像素必须位于文字模板内，应满足 $s_i = 0, v_i \notin T$ 。

为保证各笔画具有基本可识别性，要求

$$\sum_{i: v_i \in P_l} s_i \geq \lceil \gamma_l |P_l| \rceil, l = 1, 2, \dots, L. \quad (6-11)$$

6.1.3 0-1 非线性规划模型

设原始图像为

$$x \in [0, 1]^{H \times W \times C}, \quad (6-12)$$

其中 C 为颜色通道数。对像素 v_i 的所有颜色通道同时置黑，则扰动后图像满足

$$x'_{i,c}(s) = (1 - s_i)x_{i,c}, c = 1, 2, \dots, C. \quad (6-13)$$

写成向量形式为

$$x'(s) = x \odot (1 - s), \quad (6-14)$$

其中， s 在颜色通道维度上进行复制， $\odot$ 表示逐元素乘法。

设原始图像的真实类别为 y ，模型对类别 k 的输出分数为 $z_k(x)$ 。对于非定向攻击，定义分类间隔函数

$$\Phi(s) = \max_{k \neq y} z_k(x'(s)) - z_y(x'(s)). \quad (6-15)$$

当 $\Phi(s) \geq \varepsilon$ 时，认为攻击成功，其中 $\varepsilon > 0$ 为给定的安全间隔。设置正的安全间隔可以避免不同类别输出分数相等时分类规则不确定的问题。

在给定模板 T 下，面积最小的结构化置黑攻击可以表述为

$$\begin{aligned} \min \quad & \sum_{i=1}^m s_i \\ \text{s.t.} \quad & \Phi(s) \geq \varepsilon, \\ & s_i = 0, \quad v_i \notin T, \\ & \sum_{i: v_i \in P_l} s_i \geq \lceil \gamma_l |P_l| \rceil, \quad l = 1, 2, \dots, L, \\ & G[P_l \cap S] \text{连通}, \quad l = 1, 2, \dots, L, \\ & s_i \in \{0, 1\}, \quad i = 1, 2, \dots, m. \end{aligned} \quad (6-16)$$

其中， $G[P_l \cap S]$ 表示由顶点集 $P_l \cap S$ 导出的子图。目标函数为置黑像素总数；前三组约束分别保证

攻击成功、像素属于文字模板以及各笔画具有足够的保留比例；连通约束保证各笔画不会被删除成若干彼此分离的像素块。

由于攻击约束由深度神经网络给出，通常既非凸也非线性；同时，模型包含 0-1 决策变量和图连通约束。因此，模型(6-16)属于 0-1 非线性规划问题。

6.1.4 基于网络流的连通性模型

子图连通属于组约束，不能直接交由普通线性规划模型处理。参照网络流问题中的流量平衡思想，可以通过构造单源流模型，保证每个被选择的笔画像素均能够从指定根顶点到达。

对于笔画 P_l ，预先选择一个必须保留的根顶点 $r_l \in P_l$ ，并规定 $s_{r_l} = 1$ ，定义笔画 P_l 内部的有向弧集

$$A_l = \{(i, j) \in A: v_i \in P_l, v_j \in P_l\}. \quad (6-17)$$

对每条弧 $(i, j) \in A_l$ ，定义非负连续变量 $u_{ij}^{(l)}$ ，表示从顶点 v_i 向顶点 v_j 输送的辅助流量。令 $M_l = |P_l| - 1$ ，笔画连通性可由下列约束表示：

$$\begin{aligned} \sum_{j: (j, i) \in A_l} u_{ji}^{(l)} - \sum_{j: (i, j) \in A_l} u_{ij}^{(l)} &= s_i, & v_i \in P_l \setminus \{r_l\}, \\ \sum_{j: (r_l, j) \in A_l} u_{r_l j}^{(l)} - \sum_{j: (j, r_l) \in A_l} u_{j r_l}^{(l)} &= \sum_{i: v_i \in P_l \setminus \{r_l\}} s_i, \\ 0 \leq u_{ij}^{(l)} &\leq M_l s_i, & (i, j) \in A_l, \\ 0 \leq u_{ij}^{(l)} &\leq M_l s_j, & (i, j) \in A_l. \end{aligned} \quad (6-18)$$

第一组约束表示每个被选择的非根顶点恰好消耗一个单位的净流量；第二组约束表示根顶点发出的净流量等于其余被选择顶点的数量；后两组容量限制保证辅助流量只能通过被选择的顶点。如果约束组(6-18)存在可行流，则每个被选择顶点均可通过由被选择顶点构成的链与根顶点相连，从而保证导出子图 $G[P_l \cap S]$ 连通。

6.1.5 基于一阶近似的混合整数线性规划模型

模型(6-16)中最难处理的是神经网络攻击约束。为构造可求解的混合整数线性规划模型，在当前参考掩码 $s^{(q)}$ 所对应的图像 $x^{(q)} = x'(s^{(q)}) = x \odot (1 - s^{(q)})$ 附近对分类间隔进行一阶近似。

首先确定当前最具有竞争性的错误类别

$$k^{(q)} = \arg \max_{k \neq y} z_k(x^{(q)}), \quad (6-19)$$

并定义局部间隔函数

$$M^{(q)}(x) = z_{k^{(q)}}(x) - z_y(x). \quad (6-20)$$

在 $x^{(q)}$ 处进行一阶展开，有

$$M^{(q)}(x'(s)) \approx M^{(q)}(x^{(q)}) + \nabla_x M^{(q)}(x^{(q)})^\top (x'(s) - x^{(q)}). \quad (6-21)$$

由于

$$x'_{i,c}(s) - x_{i,c}^{(q)} = -x_{i,c}(s_i - s_i^{(q)}), \quad (6-22)$$

定义将像素 v_i 置黑所带来的局部攻击收益为

$$a_i^{(q)} = - \sum_{c=1}^C \frac{\partial M^{(q)}(x^{(q)})}{\partial x_{i,c}} x_{i,c}. \quad (6-23)$$

于是攻击约束可近似写为

$$\sum_{i=1}^m a_i^{(q)} s_i \geq \varepsilon - M^{(q)}(x^{(q)}) + \sum_{i=1}^m a_i^{(q)} s_i^{(q)}. \quad (6-24)$$

与绝对梯度相比, $a_i^{(q)}$ 保留了变化方向的信息。当 $a_i^{(q)} > 0$ 时, 一阶近似认为将该像素置黑有助于增大错误类别与真实类别之间的间隔。

将攻击近似约束(6-25)、模板约束、笔画保留约束和网络流连通约束结合, 可得到如下混合整数线性规划模型:

$$\begin{aligned} & \min \sum_{i=1}^m s_i \\ \text{s.t. } & \sum_{i=1}^m a_i^{(q)} s_i \geq \varepsilon - M^{(q)}(x^{(q)}) + \sum_{i=1}^m a_i^{(q)} s_i^{(q)}, \\ & s_i = 0, \quad v_i \notin T, \\ & \sum_{i: v_i \in P_l} s_i \geq \lceil \gamma_l |P_l| \rceil, \quad l = 1, 2, \dots, L, \\ & s_{r_l} = 1, \quad l = 1, 2, \dots, L, \\ & \text{满足笔画 } P_l \text{ 的网络流约束(5-2),} \quad l = 1, 2, \dots, L, \\ & s_i \in \{0, 1\}, \quad i = 1, 2, \dots, m. \end{aligned} \quad (6-25)$$

模型(6-26)的目标函数、约束函数及变量取值范围均为线性形式, 其中 s_i 为 0-1 变量, $u_{ij}^{(l)}$ 为连续变量, 因而该模型属于混合整数线性规划。

需要注意的是, 模型(6-26)仅保证一阶近似意义下的最优性。求得候选解后, 必须将对应扰动图像输入原始模型, 检验真实攻击条件 $\Phi(s) \geq \varepsilon$ 是否成立。若攻击失败, 可在当前候选图像附近重新计算梯度并再次求解, 从而形成逐次线性化过程。

6.2 反向贪心剪枝

对于 224×224 图像, 若对全部像素设置二元变量, 则共有 50176 个 0-1 变量。若进一步在全部有向弧上设置流量变量, 则最多还需引入 199808 个连续变量。考虑多个笔画、多个模板位置和多个尺度后, 模型规模将进一步增长。

因此, 实际求解时不宜直接对整幅图像建立完整模型, 而应首先利用文字模板缩小候选区域。由于模板约束规定 $s_i = 0$ 对所有 $v_i \notin T$ 成立, 实际需要保留的二元变量仅为 $|T|$ 个, 流量变量也仅需定义在各笔画内部的弧集 A_l 上。

设候选文字模板集合为 $\mathcal{T} = \{T_1, T_2, \dots, T_Q\}$, 其中不同模板可以对应不同字号、位置和字体。对每个模板, 可采用以下反向贪心方法求得面积较小的可行攻击。

首先, 将完整模板 T_q 作为初始置黑集合, 并检验其是否能够成功攻击模型。若完整模板不能攻击成功, 则舍弃该模板; 若攻击成功, 则计算当前各像素的一阶攻击收益 a_i 。随后, 按照 a_i 从小到大的顺序依次尝试删除像素。每次删除后, 均检验笔画保留率、笔画连通性和真实攻击条件。仅当全部条件仍然满足时, 接受本次删除; 否则撤销该删除操作。当不存在可继续删除的像素时, 算法停止, 并记录当前置黑面积。

该方法始终使用原始模型检验攻击是否成功, 并在删除过程中保持字形结构。由于每次只接受局部删除操作, 所得解通常为局部最优解或满意解, 但其计算成本明显低于直接求解完整混合整数规划模型。

综上, 面积最小的“张天羽”的求解流程如下: 第一, 生成不同尺度与位置的候选字形模板。第二, 删除完整置黑后仍不能成功攻击的模板。第三, 对剩余模板计算一阶攻击收益, 并筛选收益

明显较低的候选像素。第四，在缩减后的候选图上求解模型(6-26)，得到结构化置黑方案。第五，使用原始神经网络检验真实攻击条件。第六，对成功方案执行反向贪心剪枝，进一步减少置黑像素。第七，比较所有模板对应的可行方案，选择置黑面积最小者。

模型(6-26)的最优解是局部线性近似模型下的全局最优解，但不一定是原始神经网络攻击问题的全局最优解。逐次线性化与反向贪心方法能够提高候选解质量，但一般只能得到局部最优解或满意解。

6.3 实验结果

6.3.1 逆向贪心剪枝





(d) 原图: daisy (d1) 攻击图: handkerchief (d2) 扰动图
13.113% 0.1895% 面积=34

图 6-1 逆向贪心剪枝

6.3.2 一阶线性化 MILP



(a) 原图: sports car (a1) 攻击图: convertible (a2) 扰动图
14.517% 0.1045% 面积=40



(b) 原图: Persian cat (b1) 攻击图: Angora (b2) 扰动图
9.729% 0.1532% 面积=56



(c) 原图: Windsor tie (c1) 攻击图: oboe (c2) 扰动图
12.536% 1.1622% 面积=323




图 6-2 一阶线性化 MILP

表 6-1 面积最小的“张天羽”实验结果

方法	求解器	成功率	平均耗时/s	最大耗时/s	平均决策函数数值/%	平均面积
逆向贪心剪枝	manual	4/4	23.549	44.832	0.140	68.3
逆向贪心剪枝	efficient	4/4	23.495	45.210	0.140	68.3
一阶线性化 MILP	manual	4/4	12.056	21.629	0.402	113.3
一阶线性化 MILP	efficient	4/4	14.583	30.528	0.139	121.5

文字攻击与前几章的连续扰动不同，本章的决策变量是是否保留某个黑色文字像素，属于 0-1 非线性规划。若把候选文字像素看作格点图的顶点，则“张天羽”每个笔画的保留区域必须是连通子图；若再引入辅助有向弧和流量变量，连通性可以转化为类似最大流模型中的容量约束与流量平衡约束。这使第 6 章更接近组合优化和网络优化问题，而不只是连续非线性规划问题。

逆向贪心剪枝在四张图片上都得到更小的平均面积，尤其在跑车和雏菊上分别只需 37 和 34 个黑色像素即可成功。其机制相当于从一个可行解出发，不断删除当前边际贡献较低的像素，并在每一步检查攻击约束、笔画保留率和连通性。该方法的优点是最终面积小、结果直观；缺点是每次删除都需要重新验证真实模型和图结构约束，因此温莎结样本耗时达到 44.832 秒。

一阶线性化 MILP 把神经网络攻击约束在当前点附近近似为线性不等式，并与 0-1 面积目标、模板约束和网络流连通约束共同求解。它的平均耗时低于逆向贪心，但平均面积更大，尤其温莎结样本面积达到 323。这说明线性化模型在局部近似意义下能较快找到满足约束的整数可行解，却可能因为安全余量或局部梯度估计而保留更多像素。逆向贪心强调从可行解出发的局部改进，MILP 强调把 0-1 变量、线性化攻击收益和网络流约束纳入统一标准形式。两者都不是原始非凸 0-1 模型的全局最优解，但都给出了经过真实模型验证的可行满意解。

7 小组分工

表 7-1 小组分工		
姓名	占比	分工
张天羽	31%	带二范数约束的非线性规划模型（解析法）算法设计 带二范数约束的非线性规划模型（数值解法）算法设计 “让模型将任何东西识别为厕纸” 算法设计 “让模型将任何东西识别为厕纸” 代码实现 “面积最小的‘张天羽’” 算法设计 “面积最小的‘张天羽’” 代码实现
江征远	23%	带二范数约束的非线性规划模型（解析法）算法设计 带二范数约束的非线性规划模型（解析法）代码实现 化为对偶问题并求解算法设计
金震庭	23%	带二范数约束的非线性规划模型（数值解法）算法设计 带二范数约束的非线性规划模型（数值解法）代码实现 “让模型将任何东西识别为厕纸” 算法设计
田阔	23%	带二范数约束的非线性规划模型（数值解法）代码实现 化为对偶问题并求解算法设计 化为对偶问题并求解代码实现

参考文献

- [1] Goodfellow I J, Shlens J, Szegedy C. Explaining and Harnessing Adversarial Examples[J]. arXiv preprint arXiv:1412.6572, 2015.
- [2] Szegedy C, Zaremba W, Sutskever I, et al. Intriguing properties of neural networks[J]. arXiv preprint arXiv:1312.6199, 2014.
- [3] Biggio B, Roli F. Wild patterns: Ten years after the rise of adversarial machine learning[J]. Pattern Recognition, 2018.
- [4] Papernot N, McDaniel P, Goodfellow I. Practical black-box attacks against deep learning systems using adversarial examples[J]. arXiv, 2016.
- [5] Papernot N, McDaniel P, Jha S, et al. The limitations of deep learning in adversarial settings [C]//IEEE EuroS&P. 2016.
- [6] Goodfellow I J, Shlens J, Szegedy C. Explaining and Harnessing Adversarial Examples[J]. 2015.
- [7] Kurakin A, Goodfellow I, Bengio S. Adversarial examples in the physical world[J]. arXiv:1607.02533, 2016.
- [8] Kurakin A, Goodfellow I, Bengio S. Adversarial machine learning at scale[J]. arXiv, 2017.
- [9] Tramèr F, Kurakin A, Papernot N, et al. Ensemble adversarial training: Attacks and defenses [C]//ICLR. 2018.
- [10] Madry A, Makelov A, Schmidt L, et al. Towards deep learning models resistant to adversarial attacks[C]//ICLR. 2018.
- [11] Athalye A, Carlini N, Wagner D. Obfuscated gradients give a false sense of security[C]//ICML. 2018.
- [12] Tramèr F, et al. On adaptive attacks to adversarial example defenses[J]. arXiv, 2020.
- [13] Zhang H, et al. Theoretically principled trade-off between robustness and accuracy[C]//ICML. 2019.
- [14] Carlini N, Wagner D. Towards evaluating the robustness of neural networks[C]//IEEE S&P. 2017.
- [15] Carlini N, Wagner D. Adversarial examples are not easily detected: Bypassing ten detection methods[C]//IEEE S&P. 2017.
- [16] Carlini N, Wagner D. Audio adversarial examples: Targeted attacks on speech-to-text[C]//IEEE S&P Workshops. 2018.
- [17] Carlini N, Wagner D. Towards evaluating the robustness of neural networks against adversarial examples[J]. arXiv, 2016.
- [18] Moosavi-Dezfooli S M, Fawzi A, Frossard P. DeepFool: a simple and accurate method to fool deep neural networks[C]//CVPR. 2016.
- [19] Moosavi-Dezfooli S M, Fawzi A, Frossard P. Universal adversarial perturbations[C]//CVPR. 2017.
- [20] Szegedy C, et al. Intriguing properties of neural networks[J]. 2014.
- [21] Carlini N, Wagner D. Towards evaluating robustness[C]//S&P. 2017.
- [22] Chen P Y, Zhang H, Sharma Y, et al. Zoo: Zeroth order optimization based black-box attacks[C]//CCS. 2017.
- [23] Brendel W, Rauber J, Bethge M. Decision-based adversarial attacks[C]//ICLR. 2018.

- [24] Brendel W, Rauber J, Bethge M. Decision-based adversarial attacks[C]//ICLR. 2018.
- [25] Chen J, Jordan M I, Wainwright M J. HopSkipJumpAttack[J]. arXiv, 2020.
- [26] Ilyas A, et al. Black-box adversarial attacks with limited queries and information[C]//ICML. 2018.
- [27] Narodytska N, Kasiviswanathan S P. Simple black-box adversarial attacks on deep neural networks[C]//CVPR Workshops. 2017.
- [28] Moosavi-Dezfooli S M, et al. Universal adversarial perturbations[C]//CVPR. 2017.
- [29] Brown T B, Mané D, Roy A, et al. Adversarial patch[C]//arXiv:1712.09665, 2017.
- [30] Eykholt K, et al. Robust physical-world attacks on deep learning visual classification[C]//CVPR. 2018.
- [31] Thys S, Van Ranst W, Goedemé T. Fooling automated surveillance cameras: Adversarial patches[C]//CVPR Workshops. 2019.
- [32] Croce F, Hein M. Reliable evaluation of adversarial robustness with an ensemble of attacks [C]//ICML. 2020.
- [33] Croce F, Hein M. Minimally distorted adversarial examples with a fast adaptive boundary attack[J]. arXiv, 2019.
- [34] Croce F, Hein M. AutoAttack: Towards reliable evaluation of adversarial robustness[C]//ICML. 2020.
- [35] Dong Y, et al. Benchmarking adversarial robustness on ImageNet[J]. arXiv, 2020.
- [36] Athalye A, Carlini N, Wagner D. Obfuscated gradients[C]//ICML. 2018.
- [37] Tramèr F, et al. Ensemble adversarial training[C]//ICLR. 2018.
- [38] Uesato J, et al. Are labels required for improving adversarial robustness?[C]//NeurIPS. 2019.
- [39] Schmidt L, et al. Adversarially robust generalization requires more data[C]//NeurIPS. 2018.
- [40] Madry A, et al. Towards deep learning models resistant to adversarial attacks[C]//ICLR. 2018.
- [41] Wong E, Kolter J Z. Fast is better than free: Revisiting adversarial training[C]//ICLR. 2018.
- [42] Shafahi A, et al. Adversarial training for free![C]//NeurIPS. 2019.
- [43] Zhang H, et al. TRADES: trade-off between accuracy and robustness[C]//ICML. 2019.
- [44] Szegedy C, et al. Intriguing properties of neural networks[J]. 2014.
- [45] Dong Y, et al. Momentum iterative FGSM attack[C]//CVPR. 2018.
- [46] Xie C, et al. Mitigating adversarial effects through input transformations[C]//ICLR. 2018.
- [47] Sharma Y, Chen P Y, Zhang H. Zoo attack[C]//CCS. 2017.
- [48] Su J, et al. One pixel attack for fooling deep neural networks[C]//CVPR. 2019.
- [49] Carlini N, et al. On evaluating adversarial robustness[J]. arXiv, 2019.
- [50] Engstrom L, et al. A rotation and a translation suffice: Fooling CNNs with simple transformations[C]//ICLR Workshops. 2019.
- [51] Laidlaw C, Feizi S. Functional adversarial attacks[J]. NeurIPS, 2019.

附录

我们在撰写代码时，特意将手搓求解器编写成了通用模块化函数，各章脚本可以重复调用这些模块化函数，提高了项目的工程性。

因为本文代码量巨大，共计 19 个.py 文件，2396 行，若放入文中，需要约 150 页，不太合适。因此，我们只列出脚本与函数的文件树与 workflow，具体代码请见压缩包。

文件树		
文件	行数	作用
avlm_or/__init__.py	6	包导出入口
avlm_or/types.py	47	求解结果、迭代记录、决策结果等数据结构
avlm_or/model.py	161	MobileNetV2 加载、图像预处理、类别解析与决策
上下文		
avlm_or/objectives.py	47	连续攻击与定向攻击的目标函数、间隔函数和 Lagrange 松弛
avlm_or/optimal.py	60	Fritz John 与 KKT 诊断量计算
avlm_or/io.py	61	攻击图、扰动图和 CSV 结果保存
avlm_or/experiment.py	118	遍历数据集、记录原图、批量运行连续攻击
avlm_or/run.py	105	命令行入口与参数分发
avlm_or/attacks.py	445	连续扰动攻击算法调度与具体实现
avlm_or/text_attack.py	516	文字扰动模板、0-1 模型、线性化与剪枝流程
avlm_or/solvers/__init__.py	18	求解器导出
avlm_or/solvers/manual.py	384	手写最速下降、Newton/LM、DFP、共轭梯度、投影梯度、外点罚函数
avlm_or/solvers/efficient.py	78	高效后端，使用优化库加速同一数学目标
avlm_or/solvers/graph.py	118	连通分量、手写 Ford-Fulkerson 与网络流连通性检验
tests/test_graph.py	33	图与网络流求解器测试
tests/test_reference_labels.py	21	参考类别文件解析测试
tests/test_run_cli.py	60	命令行参数分发测试
tests/test_solvers.py	53	连续优化求解器测试
tests/test_text_attack.py	44	文字模板、MILP 与剪枝测试
Attacking-Vision-Language-Models/		
-- avlm_or/		主程序包，2164 行
-- __init__.py	6 行	暴露核心模型加载接口
-- run.py	105 行	CLI 入口：baseline、attack、all-continuous、text
-- experiment.py	118 行	批量实验驱动，统一遍历 datasets/*.png
-- model.py	161 行	MobileNetV2、图像预处理、原类别与决策函数
-- attacks.py	445 行	连续扰动攻击的算法分发与实现
-- text_attack.py	516 行	文字扰动的模板生成、0-1 选择、线性化与剪枝
-- objectives.py	47 行	目标函数：加权和、阈值违反、分类间隔、Lagrange 松弛

-- optimality.py	60 行	Fritz John / KKT 最优性残差诊断
-- io.py	61 行	attacked.png、perturbation.png、mask.png 与 results.csv
-- types.py	47 行	SolverResult、SolverSettings、Decision 等数据类
`-- solvers/		通用求解器
-- __init__.py	18 行	求解器统一导出
-- manual.py	384 行	手写后端，强调教材算法过程
-- efficient.py	78 行	高效后端，保持同一目标函数与输出规范
`-- graph.py	118 行	图搜索、最大流、文字笔画连通性
`-- tests/		测试代码，211 行
-- test_solvers.py	53 行	连续优化求解器正确性
-- test_graph.py	33 行	图连通与最大流
-- test_text_attack.py	44 行	文字模板和 0-1 选择模型
-- test_run_cli.py	60 行	CLI 调度参数
`-- test_reference_labels.py	21 行	人工参考类别覆盖

工作流

一、总体调用链

```
python -m avlm_or.run <command> [options]
```

```
|
```

```
v
```

```
avlm_or/run.py
```

```
解析命令行参数，构造 SolverSettings 与 AttackParameters
```

```
|
```

```
+++ baseline
```

```
|
```

```
v
```

```
| experiment.record_originals()
```

```
| 加载模型与四张原图，记录原始预测，保存 originals.csv
```

```
|
```

```
+++ attack / all-continuous
```

```
|
```

```
v
```

```
| experiment.run_batch()
```

```
| 对 datasets/1.png 至 datasets/4.png 逐张建立 ImageModelContext
```

```
|
```

```
v
```

```
| attacks.run_attack()
```

```
| 按 algorithm 选择连续扰动模型与求解器
```

```
|
```

```
v
```

```
| io.save_attack_images() + io.write_csv()
```

```
| 统一保存 attacked.png、perturbation.png、results.csv
```

```
|
```

```
+-- text
```

```
|
```

```
v
```

```
text_attack.run_text_batch()
```

生成文字模板，求解 0-1 选择模型，保存文字扰动结果

二、数据准备流程

```
datasets/*.png
```

```
|
```

```
v
```

```
model.load_context()
```

```
1. load_raw_image(): resize 到 256, 中心裁剪为 224 x 224
```

```
2. normalize(): 使用 ImageNet 均值和方差标准化
```

```
3. load_model(): 读取 models/mobilenet_v2-b0353104.pth
```

```
4. resolve_reference_class(): 若提供 reference_labels.json, 则覆盖原类别
```

```
|
```

```
v
```

```
ImageModelContext
```

提供 logits()、loss()、decision(), 供所有算法共用

说明: ImageModelContext 是连续扰动与文字扰动的公共上下文。算法层不直接处理文件路径, 而是通过该上下文访问原图张量、模型、原类别和决策函数。

三、连续扰动 workflow

```
experiment.run_batch()
```

```
|
```

```
v
```

```
attacks.run_attack(context, algorithm, backend, parameters, settings)
```

```
|
```

```
+-- analytic_first_order
```

```
| 一阶 Lagrange 满意解, 直接使用 loss 梯度并投影到二范数球面
```

```
|
```

```
+-- second_order_kkt
```

```
| 二阶 KKT 近似, 使用 Hessian-vector product 与手写线性共轭梯度
```

```
|
```

```
+-- weighted_*
```

```
| objectives.weighted_sum()
```

```
|
```

```
| +-- backend = manual:
```

```
| | solvers.manual.steepest_descent()
```

```
| | solvers.manual.levenberg_marquardt_newton()
```



```

|         |         solvers.manual.dfp_change_scale()
|         |         solvers.manual.nonlinear_conjugate_gradient()
|         |
|         +-- backend = efficient:
|             solvers.efficient.library_quasi_newton()
|
+-- projected_gradient
|     objectives.negative_loss() + solvers.manual.projected_gradient()
|     每步由 project_l2_ball() 保持二范数约束
|
+-- external_point / external_point_softplus
|     objectives.loss_threshold_violation() 或 Softplus 光滑违反量
|     solvers.manual.external_point_method()
|     内层求解器按 backend 选择手写最速下降或高效拟 Newton
|
+-- dual_loss
|     approximate_primal_dual() 对 loss 阈值模型做近似原-对偶迭代
|
+-- toilet_tissue
|     objectives.target_margin() 指向第 1000 类 toilet tissue
|     approximate_primal_dual() 求定向分类间隔满意解

```

连续扰动的输出在 `outputs/<algorithm>/<backend>/` 下。每张图保存一个子目录, 包含 `attacked.png` 与 `perturbation.png`; 整批实验另保存 `results.csv`。

四、文字扰动 workflow

```

text_attack.run_text_batch()
|
v
candidate_templates()
    枚举字体大小、顶部/中部/底部位置、旋转角度
|
v
render_text_template()
    将默认文字“张天羽”渲染为 224 x 224 的 0-1 mask
    并用 solvers.graph.connected_components() 拆分笔画连通分量
|
v
对每张图片和每个模板计算 true_margin()
|
+-- text_method = reverse_greedy
|     reverse_greedy_pruning()
|     从完整文字开始, 按线性化收益由小到大尝试删除像素
|     删除前检查保留比例、根节点和连通性

```

```
|
+-- text_method = linearized_milp
    linearized_then_prune()
    |
    +-- backend = manual:
        |         manual_linearized_selection()
        |         手写满意解过程，逐点删除低收益像素
        |
        +-- backend = efficient:
            efficient_linearized_milp()
            使用 scipy.optimize.milp 求局部 0-1 线性化模型
            连通性由网络流约束表达
        |
        v
        reverse_greedy_pruning()
        在线性化解基础上继续剪枝，减小文字扰动面积
```

文字扰动的图约束由 solvers/graph.py 支撑：

four_neighbours()	生成上下左右四邻域
connected_components()	手写 BFS，识别文字笔画分量
is_connected()	快速连通性检验
ford_fulkerson()	手写增广链最大流
network_flow_connected()	用最大流验证单根连通条件

文字扰动输出在 outputs/text_<method>/<backend>/ 下。除 attacked.png 与 perturbation.png 外，还会保存 mask.png 表示最终选择的文字像素。

五、手写后端与高效后端关系

后端	位置	用途	说明
manual	avlm_or/solvers/manual.py, avlm_or/solvers/graph.py	展示运筹学求解过程	手写 线搜索、共轭方向、DFP、外点罚函数、最大流等
efficient	avlm_or/solvers/efficient.py, text_attack.efficient_linearized_milp()	加速 实验运行	与手写后端共用模型、目标函数、输入数据和输出规范

六、结果记录流程

AttackOutcome 或 TextAttackResult

```
|
v
torch.clamp(raw_image + perturbation, 0, 1)
|
+-- context.decision()          记录攻击后模型决策
+-- io.save_attack_images()     保存攻击图和扰动强度图
```

```
+++ io.save_tensor_image(mask.png)    仅文字攻击保存
+++ io.write_csv(results.csv)         写入统一字段
```

CSV 字段由 `io.CSV_COLUMNS` 统一管理，包含图像名、算法、后端、原类别、攻击后类别、决策函数值、阈值、扰动二范数、文字面积、成功状态、耗时、迭代次数和终止信息。

七、常用运行命令

记录四张原图的原始预测：

```
python -m avlm_or.run baseline
```

运行单个连续扰动算法：

```
python -m avlm_or.run attack --algorithm weighted_dfp --backend manual --max-iterations
30
```

运行全部连续扰动算法：

```
python -m avlm_or.run all-continuous --backend manual
```

运行文字反向贪心剪枝：

```
python -m avlm_or.run text --text-method reverse_greedy --backend manual --max-checks 200
```

运行文字线性化 0-1 模型的高效后端：

```
python -m avlm_or.run text --text-method linearized_milp --backend efficient
```